



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 [学校名称]

参赛队号 [参赛队号]

队员姓名 1. [成员 A]

2. [成员 B]

3. [成员 C]

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

大语言模型的训练是参数规模 N 、数据规模 D 、数据质量 Q 与领域配比 p 在算力预算 C 下的联合配置问题。本文以真实公开数据为主、明确标注的半合成数据为辅，沿“质量评价 → 广义标度律 → 资源优化 → 能力预测”的主线建立了一套口径统一、可复算的模型体系。

问题一建立“组内平均、组间几何平均”的分层质量评价模型：将 22 个方向不一的质量指标统一为“越高越好”并在冻结参考集上做稳健归一化，按教育价值、可读性、专业性、低噪声四组聚合，组间取几何平均以体现短板效应；以组间极差 $c = \max_g z_g - \min_g z_g$ 定义质量冲突，用凸组合 $Q = (1 - \lambda)Q_{\text{base}} + \lambda \min_g z_g$ 消解。在 50412 条抽样与 205010 条扩展记录（arXiv 17438 条、GitHub 187572 条）上，域级质量自 arxiv 的 0.589 递减至 book 的 0.312，冲突率自 StackExchange 的 0.24% 升至 book 的 83.3%；冻结归一化参数后两个扩展集的域级质量与抽样集同域分别仅差 -0.0020 与 $+0.0015$ ，支持评分规则的跨集迁移。配比建模采用 17 个一次项与 136 个两两交互项的二次混料岭回归，交叉验证 RMSE 由线性模型的 0.283 降至 0.257，1M 检验集 Spearman 排序相关由 0.624 提升至 0.701，Top-5 后悔值由 0.333 降至 0.268。分析同时表明，质量分 $Q(p)$ 与线性配比项完全共线（ $R^2 = 1$ ），单独使用几乎无预测能力，故不宜作为配比回归的独立解释变量。

问题二建立含质量的有效数据量标度律 $L = E + AN^{-\alpha} + B[DQ^\kappa h(p)]^{-\beta}$ ，当 $Q = 1$ 且 $p = p_0$ 时退化为经典形式。来源诊断发现，标注为真实训练日志的 B1 其损失完全落在经典律曲面上（相对残差 2.5×10^{-4} ，元数据列与残差无关），判为公式生成，故其拟合只用于参数还原而非泛化证据；真正的泛化检验依赖 B4、B5 两个独立来源（ R^2 分别为 0.96 与 0.88）。质量指数估计为 $\kappa = 1.052$ ，bootstrap 95% 区间 $[0.982, 1.151]$ ，包含 $\kappa = 1$ 这一“质量等量折算为数据量”的简洁解释；含质量模型在 360 点上的 RMSE 为 0.117，优于常数基准 0.345。据此给出质量提升 0.1 的等效规模条件：在 $N = 1\text{B}$ 、 $D = 100\text{B}$ 处约相当于参数量增加 9.5%~20.7%。

问题三在预算约束 $D\{(6 + \eta\ell)N + [g(Q) - g(Q_0)]_+\} \leq C$ 下消去 D ，对 $(\log N, Q)$ 做粗网格加局部细化搜索，并用解析参照与一阶条件双重校验（约束残差 2.2×10^{-16} ， $|\partial L / \partial \ln N| \sim 10^{-10}$ ）。结果呈清晰的三段式结构：低预算（ $C = 10^{19}$ ）下质量投入为零、 Q^* 停在下界 Q_0 ；中等预算（ $C = 10^{22}$ ）下出现内点解 $Q^* = 0.79 \sim 0.83$ ，质量份额达 17%~22%；高预算（ $C = 10^{24}$ ）下 Q^* 触及上界 1。质量投入的启动点位于 $\log_{10} C \approx 19.6 \sim 21.1$ ，随质量成本函数与上下文长度而变。上下文长度由 2048 增至 131072 时，注意力份额自 5% 升至 67%，可分配给参数与数据的预算被显著挤压。需指出，最优规模在该损失面下辨识很弱（ $\Delta L < 10^{-4}$ 的 N 带宽达 2.3~91 倍），不应把 N^* 读作精确点估计。

问题四用 C1/C3 榜单时序、C4 算力元数据与 C8 逐任务结果，建立 $S = a + b_N \log_{10} N + rt + c \cdot \text{chat}$ 的能力模型，并以顺序平均法分解规模与非规模贡献。在固定组成子集（ $\geq 7\text{B}$ 预训练模型）上，季度能力提升 9.53 分中规模项为 -0.92 分（ -9.6% ），非规模技术进步为 $+9.64$ 分（ 101.1% ），未解释部分仅 8.5%——即这一窗口内能力增长几乎全部来自数据工程、对齐与架构等非规模因素，前沿模型参数量并未增大。Loss-Benchmark 桥接按可比性

分层拟合， R^2 仅 0.16~0.25，留一 MAE 达 7.34 分，故预测以趋势为主并显著标注该不确定性。以 2025-03-13 为起点、按算力前沿年增 0.63 dex 外推，开源模型能力前沿 12 个月后达 54.1 分（95% 区间 [52.8, 55.6]）、24 个月后达 71.0 分（[68.6, 73.7]）；若算力增长降至 0.1 倍，则分别为 50.4 与 63.7 分。由于线性趋势外推会越过样本内观测上限（52.1 分）且榜单必然饱和，该结果应读作“按现有趋势的上界估计”。时间滚动回测的 RMSE 为 7.8~9.1 分。

本文的主要特点是：对每一份数据都给出可核验的来源分级与适用边界，把“模型拟合得好”与“数据本身是生成的”区分开；对不可辨识的量（配比中的质量效应、桥接斜率、最优规模的平坦带）如实报告，不用点估计掩盖证据不足。

关键词： 标度律 数据质量 领域配比 算力约束优化 前沿预测

1 问题重述

1.1 问题背景

大语言模型的训练可以类比为培养一名学生：参数量 N 相当于脑容量，训练数据量 D 相当于阅读量，计算量 C 相当于教育经费，数据质量 Q 相当于教材质量，领域配比 p 相当于各科课时分配。标度律刻画损失随规模变化的经验关系，常见形式为 $L(N, D) = E + AN^{-\alpha} + BD^{-\beta}$ 。然而高质量语料日益稀缺、数据污染加剧，“数据墙”问题凸显；近期研究也表明，参数量小得多的模型可以凭借更高的数据质量在若干任务上胜过巨型模型^[15]。这说明质量与对比对最终能力的贡献不可忽视。

扩大参数量、增加数据量、提升数据质量和延长上下文长度都需要消耗算力，而算力是有限的。其中上下文长度越大，注意力计算与 KV 缓存等序列相关开销越高，会进一步挤压可用于参数、数据或质量提升的预算。调整领域配比本身不增加总算力开销，却会改变算力在各领域间的分配效果。四者之间存在真实的取舍，这正是本题要研究的核心矛盾。

1.2 已知条件与数据

题面提供三类附件，全部位于 `real_attachments/` 目录：

- **附件 A**（问题一）：质量信号数据 A1–A3 给出 7 个质量域、22 个质量指标的样本级评分；配方实验数据 A4–A15 给出 17 个训练域（The Pile 子领域）的配比 p 与 13 个验证域的交叉熵损失，其中 A4/A5 为训练集（512 组）、A6–A11 为检验集（1M/60M/1B 三种参数规模）、A12–A15 为外推表；A16 给出两个域体系之间的参考映射。
- **附件 B**（问题二）：B1 为 Pythia 训练日志（1176 点），B2 为 Cerebras 半合成轨迹，B3 为插值轨迹，B4/B5 为跨族与文献标度律基准，B6–B8 为含质量维度的半合成实验，B9/B10 为百亿参数以上模型的元数据与估算损失。
- **附件 C**（问题三、四）：C1/C2 为 Open LLM Leaderboard 六维评测榜单，C3 为含历史模型的扩展时序，C4 为 Epoch AI 全量模型元数据（含训练算力、数据量、权重开放性），C5/C6 为 Loss-Benchmark 桥接数据，C7 为模型架构元数据（含最大上下文长度），C8 为 1863 个模型的逐任务评测 JSON。

1.3 待求目标

四个问题构成递进主线，前一问的输出是后一问的输入：

问题一：对 22 个质量指标做预处理与综合评价，给出样本级、语料级或领域级的质量评分 Q ；定义并消解质量指标之间的冲突；利用 A4–A15 建立 17 域配比 p 与交叉熵损失的定量关系，在检验集上验证并讨论外推稳健性。

问题二：综合附件 A、B 的信息，建立同时包含 N 、 D 、 Q 、 p 的广义标度律；分析各因素的边际效用与弹性，推导质量提升与规模扩大可相互替代的条件。

问题三：在总预算 C 约束下求解 N 、 D 、 Q 、 p 的最优配置，讨论成本函数选择的影响，给出“结构性转移”的数学定义与识别方法，并解析给出上下文长度的临界值 $\ell_{\text{crit}} = 6/\eta$ 。

问题四：分离并量化规模扩张与非规模技术进步各自的贡献占比；在算力增长放缓情景下预测未来 12 或 24 个月开源大语言模型能力的前沿边界，并给出不确定性分析。

1.4 对题面概念的澄清

题面中有几处需要在建模前明确口径，本文的处理如下，具体依据见 3 节：

“全量质量信号”的含义。题面要求使用 A1 与 A2、A3 的全部记录。经核查，仓库内这四份 `.jsonl.xz` 文件均为 Git LFS 指针（132–134 字节），且 GitHub 上的 LFS 对象未上传（LFS Batch API 返回 404），实体无法获得。本文按《数据说明》给出的来源（公开数据集 SlimPajama-Meta-rater）同源重建，重建规则与核验结果见 3.2 节，并在全文显著标注。

“数据质量”的可比性。22 个指标的原始量纲与方向均不相同（如教育价值越高越好、

广告含量越低越好), 题面明确要求统一为“越高越好”。本文在冻结的参考集上估计归一化参数后再做方向补转换, 避免对每个域分别做分位数变换后直接比较域级高低。

“领域配比”的单纯形约束。配比向量满足 $p_i \geq 0$ 、 $\sum_i p_i = 1$ 。原始表的行和落在 $0.996 \sim 1.003$, 本文统一做行归一化, 且不直接对 p 取对数。

“上下文长度”的地位。按题面, ℓ 是外生情景变量而非内点寻优变量, 其可行取值依据 C7 的架构元数据。本文按 C7 中实际出现的 2048/4096/8192/32768/131072 五档取值做情景分析。

“开源”的筛选口径。题面要求问题四预测开源模型的能力前沿, 故须说明入选规则。本文给出严格口径 (C4 Open model weights? 字段为 Yes) 与宽松口径 (榜单 Hub License 非空) 两种筛选, 分别报告并以宽松口径作为主预测基准。

2 问题分析

2.1 总体思路

四个问题不是四个独立的建模任务, 而是一条串联的流水线: 问题一把原始质量信号压缩成一个可比较的标量 Q 并把配比 p 与损失挂钩; 问题二把 Q 与 p 嵌进标度律, 使“质量”具备与“规模”可换算的量纲; 问题三在此损失函数上施加算力预算约束求最优配置; 问题四再把损失翻译成可观测的 Benchmark 能力, 回答能力增长从何而来。本文的技术路线如图 2.1 所示, 研究框架如图 2.2 所示。

贯穿全文的一条纪律是**来源分级**。题面附件中既有直接观测的真实数据, 也有明确标注的半合成、插值与估算数据; 若不加区分地混用, 很容易把“生成数据的规律”误当成“真实世界的规律”。因此本文对每份数据先做可解释性诊断, 再决定它在模型中的角色, 并在结果中区分报告。

2.2 问题一分析

本问要回答三件事, 它们的技术难点各不相同。

质量评分的难点在于 22 个指标语义与量纲都不统一: 其中 8 个是多维列表 (如 modernbert * 是六分类 logits、qurater 是四维子分、ad_en 是二分类 logits), 必须先压缩成标量; 而 rps_doc_word_count 这类指标并非单调越好, 过短过长都不理想, 机械规定方向会引入偏差。本文的处理是先按语义分组, 再在组内平均、组间做几何平均——几何平均对短板敏感, 恰好对应“教材某一维度很差会拖累整体”的直觉。

质量冲突需要先给出可计算的定义。两组指标对同一文本给出显著不一致的评价时, 最直观的度量是各组得分之间的极差 $c = \max_g z_g - \min_g z_g$ 。但“不一致”不等于“某一方错了”: 教材信息量大而排版不规范是真实存在的特征, 因此消解规则应当保留这一信息而非简单取平均。本文采用算术平均与最弱组的凸组合, 强度 λ 由小规模预设网格确定并做敏感性分析。

配比建模的关键是单纯形约束。由于 $\sum_i p_i = 1$, 完整二次多项式中的截距项与平方项并不独立于一次项, 本文采用 Scheffé 规范形, 只保留 17 个一次项与 136 个两两交互项。样本量 512 对 153 个参数偏紧, 故使用岭惩罚并由交叉验证选择强度。

本问还有一个容易被忽略的陷阱: 若把质量引入配比回归, 需要注意 $Q(p) = \sum_i p_i q_i$ 本身就是 p 的线性函数, 与线性配比项**完全共线**。本文专门对此做了诊断, 结论见 5.7 节。

2.3 问题二分析

跨源融合是本问最大的困难。附件 A 与附件 B 是相互独立的实验, 验证集、tokenizer 与损失坐标都不必然一致, 不能按行直接拼接。本文的处理分三步: 先为每一份数据做“是否落在经典律曲面上”的诊断, 判断它能否提供独立的泛化证据; 再检验不同来源在基准质量处是否同尺度; 最后才做分阶段参数估计。




图 2.1 全文技术路线

模型形式上，题面提示“当教材趋于完美时新公式退化为经典形式”。本文采用有效数据量的形式，把质量与配比折算成等效的数据量：

$$L(N, D, Q, p) = E + AN^{-\alpha} + B[DQ^{\kappa}h(p)]^{-\beta}, \quad h(p_0) = 1, h(p) > 0. \quad (2.1)$$

当 $Q = 1$ 且 $p = p_0$ 时该式严格退化为经典律。这一形式的好处是 κ 有直接解释： $\kappa = 1$ 意味着“质量提升 x 倍等价于数据量提升 x 倍”， $\kappa > 1$ 则意味着质量的作用被放大。




图 2.2 研究框架与各问的方法、输出对应关系

等价条件的推导要点在于：同等损失改善既可以靠提高 Q ，也可以靠增大 N ，但两条路径的代价不同。由 L 对 N 的幂律形式可以解析解出“质量提升 ΔQ 所等效的规模增量”，但必须注意该式只在括号内为正时有有限解——括号归零意味着需要无限规模，为负则意味着单靠增大 N 根本无法实现同等收益。

2.4 问题三分析

本问是带约束的非线性优化。三个成本项共用同一个 D ，因此预算约束可整理为

$$D \{(6 + \eta\ell)N + [g(Q) - g(Q_0)]_+\} \leq C. \quad (2.2)$$

由于损失对 D 单调下降且题面未给出数据量上限，最优点处预算必然紧约束，于是可解析消去 D ，把二维搜索降为 $(\log N, Q)$ 上的无约束问题。这一化简的前提必须在实施前检查，本文在 7.5 节中逐条核验。

需要特别注意的是**结构性转移**的识别。题面用“家庭收入从 3000 元到 3 万元再到 30 万元”作类比，但仅在三个离散预算点上观察到差异并不足以证明变点存在。本文的做法是：先在连续 $\log C$ 网格上追踪最优解，再用解析参照与一阶条件确认数值解正确，最后检查观察到的变化是否在参数扰动下稳定复现。

另有一个理论上的结论需要预先说明：在本题的算力代理下，固定 ℓ 时注意力开销与训练开销之比 $C_{\text{attn}}/C_{\text{train}} = \eta\ell/6$ 是常数，因此**两者的份额之比本身不会随预算产生结构转移**。真正可能发生转移的是质量投入的存在性与强度。

2.5 问题四分析

本问的第一个难点是**口径统一**：“能力”用哪个综合分、“开源”如何筛选、“时间”按提交日期还是发布日期、模型类型如何区分“预训练”与“对话微调”。这些口径不统一，后续的贡献分解就无从谈起。

第二个难点是**避免重复计入**。数据工程带来的收益已经在 Q 与 p 中被解释过一次，若和时间趋势项里再完整计入一遍，就会高估技术进步。本文的做法是把时间项解释为“控制规模与类型后仍存在的剩余趋势”，并在正文中如实说明它还可能包含评测口径变化等遗漏因素，不把它称作因果效应。

第三个难点是**组成变化**。若直接用季度平均能力做分解，会受“提交的模型越来越小”这一组成变化污染——本文的数据确实显示季度平均参数量在下降。因此主分解建立在固定组成子集上，并另做分位数前沿的对照分解。

最后，Loss 与 Benchmark 之间的**桥接**本身误差很大（本文实测留一 MAE 达 7.34 分），必须把这一不确定性显式传播到预测区间中，而不是给一个看似精确的点预测。

3 模型假设与数据说明

3.1 模型假设

假设 1（质量可标量化）。22 个质量指标经过标量化与方向统一后，可以在同一 $[0, 1]$ 尺度上比较，且综合质量分 Q 与验证损失单调负相关。依据：题面明确要求“所有质量指标经处理后均按越高越好参与评价”；本文在 6.4.2 节用数据检验了这一单调性。

假设 2（归一化参数跨集可迁移）。稳健归一化的截尾分位参数在抽样集 A1 上估计后，可直接应用于扩展集 A2/A3。依据：A1 与 A2/A3 来自同一数据源、同一套指标定义。本文在 5.5.3 节用扩展集做了迁移检验，域级质量差异为 0.002。

假设 3（质量以有效数据量方式进入标度律）。质量对损失的作用可表示为对数据量的乘性折算 $D \rightarrow DQ^\kappa$ ，而不改变不可约损失 E 与参数项 $AN^{-\alpha}$ 。依据：该形式在 $Q = 1$ 时严格退化为经典律，符合题面提示，且 κ 可解释、可检验。本文同时报告了允许质量影响参数效率的替代模型（双通道），其参数不可辨识，见 6.4.3 节。

假设 4（预算紧约束）。题面未给出数据量上限，且损失对 D 单调下降，故最优点处预算约束取等号。依据： $\partial L/\partial D < 0$ 恒成立。本文在 7.5 节逐点核验了成本残差。

假设 5（算力代理形式）。采用题面给出的 $C_{\text{train}} = 6ND$ （Chinchilla 近似）、 $C_Q = D[g(Q) - g(Q_0)]_+$ 、 $C_{\text{attn}} = \eta ND\ell$ ，三者使用同一个 D 。这是题面指定的简化算力代理，非本文自创。

假设 6（跨源损失坐标可比）。B6 在 $Q = 1$ 、B4/B5 在其基准点上与 B1 的损失处于同一尺度。依据：本文实测 B6 在 $Q = 1$ 的 45 个点相对 B1 经典律的残差均值为 +0.0036、标准差 0.055，均值接近零，支持该假设。而 B2 的损失水平整体偏低约 1.18 nat，属不同 tokenizer/验证集，故不做绝对比较，仅用于排序验证。

假设 7（时间口径）。问题四以 C1 的提交日期为主时间轴，C2 的 Epoch AI 发布日期仅作敏感性对照，两者不混用；分析截止日 t_0 取样本内最后一个提交日 2025-03-13，不使用系统当前日期。

假设 8（开源筛选）。严格口径要求 C4 的 Open model weights? 为 Yes；宽松口径要求榜单 Hub License 字段非空。两者均要求许可证允许研究与复现。无法判定者进入未知组，不自动视作开放或关闭。

3.2 数据来源分级与完整性说明

题面要求区分真实、半合成、插值与估算数据。本文对全部 46 份数据文件逐份做了审计（清单与哈希见 results/audit_files.csv），并在此基础上做了两类必要的诊断。

3.2.1 来源分级

按题面标注与实际统计特征，本文将数据分为四级，并在全部结果中保持这一分级：

- **真实观测：**A4–A11（RegMix 配方实验）、B4/B5（跨族与文献基准）、C1–C4、C7、C8。
- **半合成：**B2（Cerebras 轨迹）、B6–B8（含质量维度的 N–D–Q 实验），由真实标度律校准后叠加噪声生成。
- **插值：**B3（Pythia 检查点插值轨迹）。
- **估算：**B10（由已拟合标度律参数估算的大模型损失）、A13/A15（由 1M/60M/1B 幂律外推的 10B/70B 损失）。

3.2.2 关键发现：B1 的损失为公式生成

B1 被题面标注为“真实训练日志”（Pythia 训练轨迹）。但本文的统计诊断显示，其 val_loss 列与经典标度律的关系异常：用五参数幂律拟合 1176 个点， R^2 达到 1.000000，RMSE 仅 1.46×10^{-4} （相对残差 5.9×10^{-5} ），已接近四位小数的舍入量级。进一步检验发现：残差与学习率、权重衰减、数值精度、批大小、训练步数的相关系数分别为 -0.001 、 $+0.015$ 、组间均值差 $< 10^{-5}$ 、 $+0.090$ 、 $+0.051$ ，即元数据列与残差无关；同时 8 个规模下的学习率各自只有一个取值，而权重衰减却有 69–76 个随机取值。这与真实训练日志的特征不符。

据此本文判定 B1 的损失列是按某个五参数标度律生成的合成轨迹（拟合还原出 $E \approx 1.69$ 、 $A \approx 0.354$ 、 $\alpha \approx 0.34$ 、 $B \approx 1.24$ 、 $\beta \approx 0.28$ 这类整齐的参数值），其 N_params_B 列的 8 个取值确实对应 Pythia 的真实非嵌入参数量。这一判定对建模的影响是：**B1 上的拟合只能用于参数还原与口径标定，不能作为泛化证据；泛化检验必须依赖 B4、B5 等含真实散布的来源。**图 6.9 给出了各来源的诊断对比。

3.2.3 缺失文件的同源重建

A1–A3 与 A18 四份 .jsonl.xz 在仓库内均为 Git LFS 指针，实体未上传，无法获得。本文按《数据说明》给出的来源（HuggingFace 公开数据集 opendatalab/SlimPajama-Meta-rater^[6]）同源重建：

- **A2**: 该数据集 arxiv/part-6777d8857c6e-000486.jsonl 全量, 剔除 content 后保留 24 个字段。重建得 **17 438** 条, 与《数据说明》记载的 17 523 条相差 0.5%, 字段结构完全一致。
- **A3**: github/part-6777d8857c6e-000275.jsonl 全量, 同样处理。重建得 **187 572** 条, 与《数据说明》记载的 203 752 条相差 7.9%, 字段结构完全一致。
- **A1**: 按 SlimPajama 自然域配比分层抽样, 在每域首分片的给定字节预算内做蓄水池抽样 (对该前缀无偏), 保留含 content 的 27 个字段。重建得 **50 412** 条 (目标 51 230 条, book 域受字节预算限制少采 788 条), 7 域分布为 commoncrawl 26 700、c4 13 700、github 2 660、arxiv 2 360、wikipedia 1 940、stackexchange 1 690、book 1 362。

重建数据的原字段名与来源数据集一致 (含原始拼写 rps_lines_ending_with_terminal_pu
本文在全部涉及质量信号的结论处均标注“同源重建”, 重建脚本与核验记录见附录。

3.3 数据使用边界

以下三点贯穿全文, 在后续各问中不再重复声明:

1. 半合成与估算数据的结果一律与真实数据分开报告, 且不作为真实泛化证据。
2. 超出数据支持范围的预测 (如 $N < 0.07B$ 或 $N > 12B$ 、 $D > 600B$) 在结果表中显式标注“外推”。
3. 区间估计一律注明生成方法: bootstrap 区间、情景包络与预测区间三者不混称“置信区间”。

4 符号说明

表 4.1 列出正文反复使用的符号。局部出现的量在首次出现处就地解释。

单位约定。附件中标量列均以十亿为单位 (如 1.04 表示 1.04×10^9), 代入 $C = 6ND$ 时须乘以 10^9 换算为实际个数; 本文全篇遵循这一约定, 并在涉及成本的结果中显式标注量级。附件 C 的 C_FLOPs_1e21 列以 10^{21} FLOPs 为单位。

下标约定。 i, j 表示 17 个训练域; k 表示 13 个验证域; g 表示 4 个质量语义组; t 表示时间 (年)。数据集编号 (A1–A18、B1–B12、C1–C10) 沿用《数据说明》的编号体系。

表 4.1 主要符号说明

符号	含义	单位/范围	备注
N	模型参数量	十亿 (B)	成本计算用实际个数
D	训练 Token 数	十亿 (B)	成本计算用实际个数
Q	综合数据质量	$(0, 1]$	越高越好
p	17 维训练领域配比	单纯形	$p_i \geq 0, \sum_i p_i = 1$
L	验证集交叉熵损失	nats	越低越好
ℓ	上下文窗口长度	token	外生情景变量
C	总算力预算	FLOPs	$C \approx 6ND$
S	综合 Benchmark 能力	0–100	越高越好
z_{ig}	样本 i 在第 g 质量组的得分	$[0, 1]$	组内指标均值
c_i	样本 i 的质量冲突强度	$[0, 1]$	$\max_g z_g - \min_g z_g$
τ	冲突判定阈值	$[0, 1]$	开发集 75% 分位
λ	冲突消解强度	$[0, 1]$	主用 0.3
κ	质量折算指数	> 0	主估计 1.052
$h(p)$	配比调节因子	> 0	$h(p_0) = 1$
E, A, α, B, β	经典标度律参数	—	见 6.2 节
v_k	13 个验证域的评价权重	等权 1/13	不随 p 改变
η	注意力开销系数	2×10^{-4}	题给常数
$g(Q)$	单位数据质量成本	FLOPs/token	题给三类形式
Q_0	基线数据质量	0.5	优化下界
a_k, b_{kij}	二次混料回归系数	—	Scheffé 规范形
ε_x	对变量 x 的弹性	无量纲	$\frac{\partial L}{\partial x} \frac{x}{L}$
ΔL_Q	质量提升 0.1 的损失改善	nats	$L(Q) - L(Q + 0.1)$
N_{eq}	质量改善的等效参数规模	十亿 (B)	见式 (6.17)
U	归一化后的指标得分	$[0, 1]$	方向已统一
ε	几何平均零值截断	10^{-3}	敏感性已检验

5 问题一：数据质量评价、冲突消解与领域配比建模

5.1 质量指标的预处理与标量化

附件 A 的 22 个指标中，14 个是标量、8 个是列表型。列表型必须先压缩为标量。按各指标的原始语义分别处理：

- fineweb_edu 为单元素列表，直接取该元素。
- modernbert_cleanliness/readability/reasoning/professionalism 为六分类 logits，本文取 $\arg \max / 5$ 作为等级得分，使取值落入 $[0, 1]$ ；作为敏感性对照另做了 softmax 期望 $\mathbb{E}[c] = \sum_c p_c c / 5$ 。
- fluency_en 为二分类 logits，取 softmax 后流畅类的概率。
- ad_en 的官方类别顺序为 [has_ad, no_ad]，取第二类（无广告）的 softmax 概率，该值本身已是正向。
- qurater 是四个语义子维度的评分而非分类 logits，不能做 softmax。本文对四个维度各自做标准化后取平均，避免量纲差异主导。
- 8 个 rps_* 指标为标量，按各自语义处理。

5.2 方向统一与稳健归一化

题面要求把所有指标统一为“越高越好”。本文的处理分两步，顺序不能颠倒：

先在冻结的参考集（A1 抽样集）上估计归一化参数：对每个指标取 1% 与 99% 分位

作为截尾边界，再线性映射到 $[0, 1]$ ，即

$$U_{im} = \text{clip}\left(\frac{x_{im} - \ell_m}{h_m - \ell_m}, 0, 1\right), \quad (5.3)$$

其中 ℓ_m, h_m 为指标 m 的 1%/99% 分位。截尾是为了避免个别极端值把整个尺度压缩。该参数一经确定即应用于 A2/A3，不对每个域分别做分位数变换——否则域间的高低比较将失去意义。

再对**明确负向**的指标做补转换 $U \leftarrow 1 - U$ 。本文识别出 6 个负向指标：ad_en（广告）、rps_doc_frac_chars_top_2gram 与_top_3gram（n-gram 重复率）、rps_lines_uppercase_1（大写行占比）、rps_doc_frac_no_alph_words（非字母词占比）、rps_lines_numerical_chars（数字字符占比）。

有一类指标需要特别处理：rps_doc_word_count（词数）与 rps_doc_num_sentences（句数）并非单调越好——过短说明信息量不足，过长往往是未清洗的拼接文本。本文对这两个指标采用倒 U 型效用，峰位设在归一化后的 0.35 处：

$$U \leftarrow 1 - \frac{|U - 0.35|}{\max(0.35, 0.65)}. \quad (5.4)$$

5.3 分层综合质量评分模型

5.3.1 语义分组

按 SlimPajama-Meta-rater 数据卡的指标语义，将 22 个指标分为 4 组：

表 5.2 质量语义分组

组别	含义	包含指标
教育价值	文本的知识密度与学习价值	教育价值、DSIR 书籍/百科/数学、质量评分、推理性
可读性	语言流畅与结构清晰	可读性、洁净度、流畅度、一元熵
专业性	术语规范与表达严谨	专业性、平均词长、唯一词比
低噪声	广告、重复与格式噪声	无广告、非字母词比、2/3-gram 重复、大写行比、终止标点比、数字字符

5.3.2 组内平均与组间几何平均

对样本 i ，先取组内算术平均得 z_{ig} ，再取组间几何平均得基础质量分：

$$Q_i^{\text{base}} = \left(\prod_{g=1}^4 (z_{ig} + \varepsilon) \right)^{1/4} - \varepsilon, \quad \varepsilon = 10^{-3}. \quad (5.5)$$

选几何平均而非算术平均，是因为几何平均对短板敏感：只要有一个组得分很低，整体得分就会被显著拉低，这与“教材存在明显缺陷时整体质量不高”的判断一致。 ε 用于避免零值导致对数发散，其取值在 $10^{-4} \sim 10^{-2}$ 范围内对结果排序几乎无影响（敏感性见 5.5.2 节）。

图 5.3 给出 22 个指标的相关结构与语义分组。可以看出同组指标普遍正相关，但组间相关性较弱甚至为负——尤其“教育价值”与“低噪声”两组几乎不相关，这正是冲突产生的结构性原因。




图 5.3 质量指标相关结构与分组

5.4 质量冲突的定义、成因与消解

5.4.1 冲突的数学定义

设 z_{ig} 为样本 i 在第 g 组的得分。本文把冲突强度定义为组间极差：

$$c_i = \max_g z_{ig} - \min_g z_{ig}. \quad (5.6)$$

选极差而非方差，是因为极差直接对应“最好的维度与最差的维度相差多少”，量纲与 Q 一致、易于解释，且不受组数影响。阈值 τ 由开发参考集上 c 的 75% 分位确定，得 $\tau = 0.577$ ； $c_i > \tau$ 标记为冲突样本。本文另做了多个阈值的敏感性分析。

需要强调的是：范围差只能发现不一致，不能证明某一指标错误。文本确实可能同时“信息密度高”与“格式噪声大”（论坛长帖、代码注释），这属于真实特征而非测量错误。

5.4.2 冲突的成因剖析

图 5.4 展示了冲突的结构。左图是教育价值与低噪声两组的联合分布，散点沿对角线两侧明显铺开，说明两者相关性很弱。中图给出各域冲突率：StackExchange 仅 0.24%，而 book 域高达 83.3%。右图把冲突归纳为五类典型模式。

冲突率在域间的巨大差异说明冲突主要是体裁特征而非测量故障。book 域多为扫描或早期数字化的长文本，教育价值评分高但格式规范性差、非字母字符比例高，因而“教育价值高、噪声控制差”这一类冲突占比最高。这一解释与图 5.4(c) 中该类型占比最大相互印证。




图 5.4 质量冲突的结构与典型模式

5.4.3 消解规则

本文采用基础分与最弱组的凸组合：

$$Q_i^{(\lambda)} = (1 - \lambda) Q_i^{\text{base}} + \lambda \min_g z_{ig}, \quad 0 \leq \lambda \leq 1. \quad (5.7)$$

$\lambda = 0$ 即不处理冲突（消融对照）， λ 越大越强调短板约束。 λ 由小规模预设网格 $\{0, 0.1, \dots, 0.5\}$ 确定，本文取 $\lambda = 0.3$ 。图 5.8(b) 给出 λ 的影响：随 λ 增大，质量分均值由 0.557 单调降至 0.433，但与 $\lambda = 0$ 结果的 Spearman 秩相关仍高达 0.966，说明消解规则改变了分数的绝对水平却基本保持了排序，是一个“温和”的修正。

该规则满足一个必要的一致性要求：若单独改善某一指标， Q 不会下降。

5.5 质量评分结果

5.5.1 域级质量

表 5.3 与图 5.5、图 5.6 给出域级结果。

表 5.3 七个质量域的域级质量与冲突率

域	样本数	平均 Q	2.5% 分位	97.5% 分位	冲突率
arxiv	2 360	0.589	0.482	0.651	4.2%
stackexchange	1 690	0.552	0.421	0.644	0.2%
commoncrawl	26 700	0.482	0.337	0.633	29.6%
github	2 660	0.479	0.254	0.626	13.2%
wikipedia	1 940	0.475	0.331	0.621	7.8%
c4	13 700	0.474	0.299	0.633	21.6%
book	1 362	0.312	0.100	0.535	83.3%

结果呈现清晰的层次：学术类文本（arxiv、stackexchange）质量最高且一致性最好，网页抓取类（commoncrawl、c4）居中且内部离散度大，book 域质量最低但方差最大。图 5.6(a) 的雷达图进一步显示，book 在“低噪声”与“专业性”两维上明显塌陷，而其“教育价值”并不差——这正是它冲突率高达 83.3% 的原因。

5.5.2 聚合方式与敏感性

题面要求说明由样本向语料或领域的聚合方式。本文以文档等权为主口径，另报告按词数加权的对照。二者的差异很小（如 commoncrawl 为 0.482 对 0.477），说明域级结论不依赖于聚合权重。需说明的是，词数是按空格切分的粗略计数，不能等同于 tokenizer 的




图 5.5 各域质量分布、累积分布与冲突强度




图 5.6 域级质量画像与不确定区间

Token 数，故仅作为对照。

表 5.4 汇总了敏感性检验。 ϵ 截断在三个量级上给出几乎相同的排序(秩相关 ≥ 0.99999)；标量化方式改用 softmax 期望后秩相关为 0.977，结论稳健。但合成方式的影响很大：改用等权算术平均后秩相关降至 0.665，用全指标几何平均降至 0.668。这说明“分组 + 组间几何平均”这一结构本身携带了信息，不是任意组合都能替代。

表 5.4 质量评分敏感性检验

检验项	取值	与主结果秩相关	Q 均值
ϵ 截断	10^{-4}	1.0000	0.482
	10^{-3} (主)	1.0000	0.482
	10^{-2}	0.99999	0.483
标量化方式	softmax 期望	0.977	0.485
合成方式	等权算术平均	0.665	0.631
	全指标几何平均	0.668	0.427

5.5.3 扩展集迁移检验

题面要求在扩展集上检验主要结论。本文将 A1 上冻结的归一化参数直接应用于两个扩展集，结果见表 5.5。

两个扩展集的域级质量与 A1 同域的差异分别为 -0.0020 与 $+0.0015$ ，冲突率的差异同样很小 (arxiv 5.03% 对 4.19%，github 14.16% 对 13.16%)。A3 的样本量是 A1 中 github

表 5.5 扩展集迁移检验（归一化参数在 A1 上冻结，不做任何重标定）

扩展集	条数	域	扩展集平均 Q	A1 同域平均 Q	差异
A2	17 438	arxiv	0.5874	0.5894	-0.0020
A3	187 572	github	0.4803	0.4788	+0.0015

域的 71 倍，仍给出几乎相同的域级质量，这一结果有力支持假设 2——评分规则与归一化参数可以跨集迁移，域级质量是语料的稳定属性而非抽样偶然。

5.6 领域配比建模

5.6.1 模型形式

配比 p 位于单纯形上。由于 $\sum_i p_i = 1$ ，完整二次多项式中的常数项与平方项与一次项不独立，会产生冗余。本文采用 Scheffé 规范形：

$$\hat{L}_k(p) = \sum_{i=1}^{17} a_{ki} p_i + \sum_{i < j} b_{kij} p_i p_j, \quad k = 1, \dots, 13. \quad (5.8)$$

共 17 个一次项与 $\binom{17}{2} = 136$ 个交互项，每个目标域 153 个参数。训练样本仅 512 组，故引入岭惩罚：

$$\min_{a,b} \sum_n \left(L_k^{(n)} - \hat{L}_k(p^{(n)}) \right)^2 + \alpha \left(\sum_i a_{ki}^2 + \sum_{i < j} b_{kij}^2 \right), \quad (5.9)$$

惩罚强度 α 由 A4/A5 上的 5 折交叉验证在 22 个对数网格点上选取。交互列乘以 17 以对齐量级，使惩罚对各列公平。评价目标为 13 个验证域的等权平均

$$L_{\text{eval}}(p) = \sum_{k=1}^{13} v_k \hat{L}_k(p), \quad v_k = \frac{1}{13}, \quad (5.10)$$

权重 v 固定且不随 p 改变。需说明的是，17 个训练域中有 4 个（nih_exporter、enron_emails、europarl、philpapers）没有对应的验证损失列，它们仍作为配比输入参与建模，但不虚构其验证损失。

5.6.2 二次项的价值

表 5.6 与图 5.7 给出线性模型与二次混料模型的对比。二次项的引入把交叉验证 RMSE 从 0.283 降到 0.257， R^2 从 0.240 提高到 0.375，Spearman 排序相关从 0.497 提高到 0.649。在保留的 1M 检验集上，二次模型的优势同样明显（RMSE 0.199 对 0.228，Spearman 0.701 对 0.624）。这说明领域之间确实存在非加性的搭配效应，不是简单线性叠加。

表 5.6 中 60M 与 1B 检验集的 R^2 为大幅负值，这不是模型失败，而是尺度不可比：模型在 1M 规模的损失上训练，而 60M/1B 的损失绝对水平显著更低，直接套用会产生系统性偏差。因此对这两个检验集应当只看排序指标。二次模型在 60M 上的 Spearman 达 0.706，说明配比优劣的排序确实可以跨参数规模迁移。若在检验集的一半上拟合仿射尺度校准、在另一半上评估，二次模型在 60M 上的 RMSE 由 1.466 降至 0.161，进一步印证了偏差主要来自尺度而非排序。

5.6.3 选方后悔值

题面要求给出“预测最优配方的真实损失减去候选集真实最小损失”的后悔值。表 5.7 给出结果：在 1M 检验集上，二次模型的 Top-1 后悔值为 0.414，优于线性模型的 0.709；

表 5.6 配比模型的交叉验证与检验集表现

数据集	模型	RMSE	MAE	R^2	Spearman
训练集 5 折 CV	线性混料	0.283	0.225	0.240	0.497
	二次混料	0.257	0.199	0.375	0.649
1M 检验集 A6/A7	线性混料	0.228	0.181	0.327	0.624
	二次混料	0.199	0.158	0.485	0.701
60M 检验集 A8/A9	线性混料	1.520	1.508	-47.3	0.558
	二次混料	1.467	1.456	-43.9	0.706
1B 检验集 A10/A11	线性混料	3.194	3.190	-3782	0.367
	二次混料	2.830	2.822	-2968	0.478




图 5.7 配比模型的交叉验证、排序能力与后悔值

Top-5 后悔值 0.268 对 0.333。作为参照，随机选方的平均后悔值为 0.534。

表 5.7 选方后悔值（越低越好）

检验集	模型	Top-1	Top-5	Top-10	随机选方
1M	线性混料	0.709	0.333	0.262	0.534
	二次混料	0.414	0.268	0.268	
60M	线性混料	0.618	0.299	0.217	0.380
	二次混料	0.288	0.186	0.175	
1B	线性混料	0.116	0.120	0.103	0.114
	二次混料	0.333	0.134	0.102	

需要如实报告一个负面结果：在 1B 检验集上，二次模型的 Top-1 后悔值（0.333）反而高于线性模型（0.116），也高于随机选方。1B 检验集只有 64 个候选配方，Top-1 统计量本身波动很大，不宜据此下强结论；但这一现象提示二次模型在样本量小的场景下可能过拟合。在 10B/70B 外推表上，两个模型的 Spearman 秩相关均为负（-0.45 ~ -0.71），说明配比优劣的排序无法外推到数十亿参数以上——这是外推表的固有局限（A12–A15 是由 1M/60M/1B 幂律外推生成的估算值，不是独立实验），本文不把它当作真实泛化证据。

5.6.4 交互项的稳定性

图 5.8(a) 给出交互项系数。用 bootstrap（200 次重采样）估计系数标准差后，1768 个交互系数中有 482 个（27.3%）满足 $|b|/sd > 2$ 。这说明大约四分之一的搭配效应在不同重采样下稳定存在。但必须强调：单个交互系数只表示相对该模型线性混合预测的偏离，不

能直接读作“某两个领域互补/互斥”的因果结论——要得到替代或互补的判断，还需做单纯形上的可行方向扰动，这部分放在 6.5.3 节与问题二一并讨论。




图 5.8 交互项系数与冲突消解强度的敏感性

5.7 是否引入质量评分 Q ：一个重要的识别问题

题面把“是否以及如何引入质量评分 Q ”留给参赛队论证。本文对此做了专门检验，结论是不应把 Q 作为配比回归中的独立解释变量，理由如下。

5.7.1 完全共线

若定义配比层面的综合质量

$$Q(p) = \sum_{i=1}^{17} p_i q_i, \quad (5.11)$$

其中 q_i 为第 i 个训练域的域级质量，则 $Q(p)$ 是 p 的线性函数。用 17 个线性配比项回归 $Q(p)$ ，得 $R^2 = 1.0000000000$ ——完全共线。在无惩罚的最小二乘中，加入 $Q(p)$ 不提供任何新信息，其系数不可单独辨识。

5.7.2 实证检验

表 5.8 给出三种模型在同一训练/检验切分下的表现：

表 5.8 引入 $Q(p)$ 的三种方式对比（5 折交叉验证）

模型	每域参数	CV RMSE	CV MAE	CV R^2	CV Spearman
二次混料（基准）	153	0.257	0.199	0.375	0.649
二次混料 + $Q(p)$	154	0.228	0.179	0.508	0.700
纯质量模型 $a_k + c_k Q(p)$	2	0.326	0.258	-0.009	-0.096

纯质量模型几乎完全没有预测能力（ $R^2 = -0.009$ ，Spearman 为负），13 个目标域中只有 4 个的 c_k 为负（即符合“质量越高损失越低”的预期）。这说明单个质量标量无法承载配比与损失之间的关系。

加入 $Q(p)$ 确实改善了留出表现（CV RMSE 0.257→0.228，1M 检验 RMSE 0.199→0.183），但由于存在完全共线，这一改善来自岭惩罚结构的变化而非新信息—— $Q(p)$ 乘以 17 后作为一个特定线性组合被单独惩罚，等价于对原系数施加了一个有方向的收缩。因此不能把 c_k 解释为“质量的独立效应”。

5.7.3 结论

质量信息应当通过问题二的有效数据量形式 DQ^k 进入模型，而不是作为配比回归的加性项。这既避免了共线性，又赋予质量与数据量可比量纲。本文后续采用这一路线。

5.8 跨体系域映射

两个域体系并不一一对应。A16 给出参考映射：arxiv、github、stackexchange 为 direct，wikipedia_en→wikipedia、gutenberg_pg_19→book、pile_cc→commoncrawl 为 near_direct，其余 11 个配方域没有同名质量域。本文按文本体裁为它们指定代理，映射规则与依据见表 5.9。

表 5.9 配方域到质量域的映射与代理指派

配方域	质量域	映射
arxiv, github, stackexchange	同名域	direct
wikipedia_en	wikipedia	near
gutenberg_pg_19	book	near
pile_cc	commoncrawl	near
dm_mathematics, nih_exporter, pubmed_central, philpapers, pubmed_abstracts, uspto_backgrounds	arxiv	infer
ubuntu_irc, hackernews	stackexchange	infer
freelaw, europarl	wikipedia	infer
enron_emails	commoncrawl	infer

代理指派的依据是文本体裁：学术论文全文与摘要归入 arxiv，技术问答与社区讨论归入 stackexchange，正式书面语归入 wikipedia，非正式日常文本归入 commoncrawl。得到 17 维质量向量 q ，均值 0.527、范围 [0.312, 0.589]。

这一映射是建模假设而非已验证事实：13 个域没有实测的质量信号，其 q_i 值来自体裁代理。因此本文在后续只把 q 用于构造 $Q(p)$ 这一单调折算，而不据此宣称任何域级的因果效应，并在敏感性分析中检验代理误差的影响。

6 问题二：跨维度数据融合与广义标度律

6.1 来源诊断：先分清哪些数据能作证据

题面指出附件 A 与附件 B 的实验相互独立，需提出可检验的假设把不同来源统一到同一模型中。在建模之前，本文先对附件 B 的八份数据做了“是否落在经典律曲面上”的诊断：对每份数据独立拟合五参数幂律 $L = E + AN^{-\alpha} + BD^{-\beta}$ ，观察拟合优度与残差结构。结果见表 6.10 与图 6.9(d)。

B1 的诊断需要单独说明（详见 3.2.2 节）。它的 R^2 精确等于 1、RMSE 已接近四位小数的舍入量级，且学习率、权重衰减等元数据列与残差完全无关。本文据此判定其损失列为公式生成。这一判定直接改变了建模策略：**B1 上的拟合只用于口径标定与参数参照，不能作为泛化证据**；泛化能力必须由含真实散布的 B4、B5 来检验。

B2 的 $R^2 = 0.9995$ 同样接近公式生成，与其“半合成”标注一致。B3（插值轨迹）拟合 $R^2 = 0.99996$ ，与“插值”标注一致。值得注意的是，B2 的损失水平整体比 B1 低约 1.18 nat，这是不同 tokenizer 与验证集导致的坐标平移，故 B2 只能用于族内排序验证，不能做绝对水平比较。

表 6.10 标度律数据集的来源诊断

数据集	题面标注	点数	RMSE	R^2	诊断
B1 Pythia 训练日志	真实	1 176	1.46×10^{-4}	1.000000	公式生成
B2 Cerebras 轨迹	半合成	1 029	0.011	0.9995	公式生成
B4 跨族收敛点	真实	57	0.088	0.964	含真实散布
B5 文献基准	真实	44	0.132	0.880	含真实散布
B6 NQ 半合成	半合成	360	0.129	0.860	含真实散布
B7 NQ 扩展	半合成	450	0.118	0.880	含真实散布
B8 NQ 大规模	半合成	1 704	0.651	0.128	含真实散布（含外推点）
B10 大模型估算	估算	128	2.9×10^{-5}	1.000000	公式生成




图 6.9 经典标度律拟合、残差与来源诊断

6.2 经典标度律的拟合

虽然 B1 是生成的，其标度律形式与参数仍可作为口径参照。本文对 B1 的 1176 个唯一 (N, D) 点拟合

$$L_0(N, D) = E + AN^{-\alpha} + BD^{-\beta}, \quad (6.12)$$

采用对数参数化的有界非线性最小二乘（保证参数为正）并做 60 次多起点搜索以避免局部极小。结果见表 6.11。

参数值接近 $E = 1.69$ 、 $A = 0.354$ 、 $\alpha = 0.34$ 、 $B = 1.24$ 、 $\beta = 0.28$ 这类整齐取值，进一步支持“B1 由该组参数生成”的判断。区间极窄（相对宽度 $< 10^{-3}$ ）也正说明数据本身没有观测噪声——真实实验不可能给出如此精确的参数。

表 6.11 经典标度律参数估计 (B1, 1176 点)

参数	估计值	bootstrap 95% 区间	说明
E	1.6898	[1.6897, 1.6899]	不可约损失
A	0.35398	[0.35392, 0.35406]	参数项系数
α	0.33998	[0.33992, 0.34003]	参数规模指数
B	1.24031	[1.24019, 1.24044]	数据项系数
β	0.27988	[0.27983, 0.27993]	数据规模指数
训练 RMSE = 1.46×10^{-4} , $R^2 = 1.000000$			

6.2.1 分组留出验证

B1 中同一模型的 147 个检查点高度相关, 随机拆行会严重低估误差。本文采用两种分组留出:

- **逐规模留一:** 留出某一参数量规模的全部 147 个点, 用其余 7 个规模拟合。8 次留出的 RMSE 在 $1.0 \times 10^{-4} \sim 2.2 \times 10^{-4}$ 之间。
- **D 方向后段外推:** 每个规模按数据量排序, 留出末 25% (共 296 点)。RMSE 为 1.1×10^{-4} 。

两类留出的误差都停留在舍入量级, 再次印证数据无噪声。因此这些留出误差不能作为模型泛化能力的证据, 真正的泛化检验见 6.6 节。

6.3 跨源可比性检验

建立统一模型的前提是不同来源的损失处于同一坐标。本文用 B6 在 $Q = 1$ 处的 45 个点检验: 它们相对 B1 经典律的残差均值为 +0.0036、标准差 0.055、95% 区间 $[-0.100, +0.102]$ 。均值接近零, 支持 “B6 的 $Q = 1$ 基准与 B1 同尺度” 这一假设 (假设 6)。这使两阶段估计成为可能: 先用 B1 标定 E, A, α, B, β , 再在 B6 上估计质量指数 κ 。

6.4 广义标度律

6.4.1 模型形式

本文采用有效数据量形式:

$$L(N, D, Q, p) = E + AN^{-\alpha} + B [D Q^{\kappa} h(p)]^{-\beta} \quad (6.13)$$

其中 $h(p)$ 为配比调节因子, 满足 $h(p_0) = 1$ 、 $h(p) > 0$ 。该形式在 $Q = 1$ 且 $p = p_0$ 时严格退化为经典律, 符合题面要求。三项的含义是: E 为不可约损失, 第二项为参数规模的贡献, 第三项为 “有效数据量” 的贡献。

配比因子取

$$h(p) = \exp \left\{ -\omega \frac{f(p) - f(p_0)}{s_f} \right\}, \quad (6.14)$$

其中 f 为问题一的配比预测器, s_f 为该预测器在训练参考集上损失预测值的尺度, $\omega \geq 0$ 为无量纲的迁移强度。 $f(p)$ 越低 (配比越好) 则 $h(p)$ 越大, 等效数据量越多。这里需要如实说明: 附件 B 的 N-D-Q 实验不含配比维度, 因此 ω 与附件 A 之间没有共同实验, 无法由数据辨识。本文把它作为情景变量 (取 $\omega \in \{0, 0.5, 1, 2\}$), 在 7 节传入问题三, 而不谎称已精确估计。

6.4.2 质量指数的估计

在 B6 的 360 个点上，先固定 B1 标定的经典参数、只估计 κ ，再做联合估计作为对照。结果见表 6.12 与图 6.10。

表 6.12 质量指数 κ 的估计

数据集	估计方式	κ	RMSE	常数基准 RMSE
B6 (360 点, 主)	分阶段 (固定经典参数)	1.052	0.117	0.345
	联合估计	1.217	0.073	
B7 (450 点, 对照)	分阶段	1.076	0.115	0.341
B8 (1704 点, 外推)	分阶段	不可用	1.185	0.697




图 6.10 质量—损失关系、 κ 的剖面似然与跨来源泛化

分阶段估计得 $\kappa = 1.052$ ，bootstrap 95% 区间为 [0.982, 1.151]。该区间包含 $\kappa = 1$ ，即“质量提升 x 倍等价于数据量提升 x 倍”这一最简洁的折算关系与数据相容。用 B7 独立复核得 $\kappa = 1.076$ ，与主估计相差 2.3%，说明结论稳健。

联合估计（6 个参数全部自由）得 $\kappa = 1.217$ 、RMSE 0.073，优于分阶段。但联合估计的参数与 B1 标定的经典参数差异较大（如 β 从 0.280 降到 0.070），说明 **B6 自身的基线**与 **B1 并不完全一致**，此时把 κ 单独解释为质量效应并不干净。本文以分阶段估计为主报告，联合估计作为上界对照。图 6.10(b) 的剖面似然曲线在 κ 偏离 1 时迅速上升，进一步确认了估计的稳定性。

B8 不可用于分阶段估计：它含有 N 达 700B 的外推点，远超 B1 的支持范围（最大 11.97B），固定经典参数会严重失配（RMSE 1.185，与常数基准 0.697 相比反而更差）。本文如实报告这一失败，不强行给出 κ 。

6.4.3 替代模型与不可辨识性

为检验“质量是否也提升参数利用效率”，本文另拟合了双通道模型

$$L = E + A[NQ^\rho]^{-\alpha} + B[DQ^\kappa h(p)]^{-\beta}. \quad (6.15)$$

在 B6 上， ρ 与 κ 的估计高度相关，置信区间互相覆盖，参数不可辨识——这与“质量的作用位置无法由现有数据区分”的预期一致。因此本文保留双通道模型为未辨识对照，主结论退回有效数据量形式。

6.5 边际效用、弹性与替代条件

6.5.1 弹性

对式 (6.13) 求偏导，得解析弹性：

$$\varepsilon_N = \frac{\partial L}{\partial N} \frac{N}{L} = -\frac{\alpha A N^{-\alpha}}{L}, \quad \varepsilon_D = -\frac{\beta B X^{-\beta}}{L}, \quad \varepsilon_Q = -\frac{\kappa \beta B X^{-\beta}}{L}, \quad (6.16)$$

其中 $X = DQ^\kappa h(p)$ 。三者均为负，表示增大任一因素都降低损失。图 6.11(a)(b) 给出弹性在 (N, D) 平面上的分布。




图 6.11 弹性与质量改善的等效规模

可以读出两个规律。其一， ε_N 的绝对值随 N 增大而减小、随 D 增大而增大； ε_D 则相反。这体现了边际收益递减与两因素的相互补充。其二，在本文数据支持的范围内， $|\varepsilon_D|$ 通常小于 $|\varepsilon_N|$ ，意味着在相同比例投入下，扩大参数规模比增加数据量更能降低损失——这与 $\beta < \alpha$ 一致。

需要强调，本节的弹性是相对于总损失 L 定义的。若改用可约损失 $L - E$ 作分母，数值会显著放大（因为 $E \approx 1.69$ 占总损失的主要部分），两者不可混用。本文报告的是总损失弹性。

解析弹性另用中心差分核验：在 $(N, D) = (1, 100)$ 与 $(10, 1000)$ 处，解析值与差分值的绝对偏差分别为 1.8×10^{-12} 与 3.2×10^{-13} ，一致性达机器精度。

6.5.2 质量提升 0.1 的等效规模

定义质量改善收益 $\Delta L_Q = L(N, D, Q, p) - L(N, D, Q + 0.1, p)$ 。在有效数据量模型下，令参数项增加 ΔL_Q 即可匹配这一改善，解得

$$N_{eq} = \left[N^{-\alpha} - \frac{\Delta L_Q}{A} \right]^{-1/\alpha}. \quad (6.17)$$

该式只在括号内为正时有有限解：括号等于零意味着需要无限规模，小于零则意味着仅靠增大 N 根本无法实现同等收益。表 6.13 给出代表性结果，全部落在可行域内。

结论有两点。第一，等效规模强烈依赖于基准点，不能给出全局固定的替代率——在 $N = 1B$ 、 $D = 100B$ 、 $Q_0 = 0.5$ 处，质量提升 0.1 相当于参数量增加 20.7%；而在 $Q_0 = 0.9$ 处只相当于 9.5%，因为质量已接近上限、继续提升的空间变小。第二，在小模型（ $N = 0.1B$ ）处质量改善的等效规模不足 0.2%，说明小模型上提升数据质量的收益在参数维度上几乎无法被察觉——但从绝对损失看收益依然存在，只是无法用“加参数”来等价替代。

表 6.13 质量提升 0.1 的等效参数规模 ($D = 100B$)

$N(B)$	Q_0	$L(Q_0)$	$L(Q_0 + 0.1)$	ΔL_Q	$N_{eq}/N - 1$
0.1	0.5	2.8073	2.8070	0.00035	+0.13%
0.1	0.9	2.8062	2.8060	0.00020	+0.08%
1.0	0.5	2.4630	2.4411	0.02192	+20.7%
1.0	0.7	2.4234	2.4088	0.01464	+13.2%
1.0	0.9	2.3964	2.3856	0.01077	+9.5%
10.0	0.5	2.1013	2.0875	0.01380	+12.6%

6.5.3 领域替代与互补

题面要求讨论不同领域数据之间的替代或互补关系。这里的正确做法是在单纯形上做可行方向扰动：令 p_i 增加 δ 、 p_j 减少 δ ，其余不变，观察 L_{eval} 的变化。不能把 p_i 与 p_j 同时增加（违反 $\sum p_i = 1$ ），也不能直接读交互项系数。

对问题一得到的固定配比 p_0 ，本文计算了全部 $\binom{17}{2} = 136$ 个方向的局部斜率 $g_{ij} = \partial L_{eval} / \partial \delta|_{\delta=0}$ 。斜率为负的方向表示“把占比从 j 转向 i ”能降低损失。由于 5.7 节已说明单系数不可作因果解读，本节只报告方向的符号与相对大小，并注明这是局部一阶信息，不构成全局最优的替代方案——全局的配比优化在问题三中处理。

6.6 验证与适用范围

表 6.14 给出广义模型（经典参数直接外推）在各来源上的表现。这是本文对“模型到底有多可信”的核心回答。

表 6.14 跨来源验证（经典参数直接外推，不做任何校准）

来源	性质	点数	RMSE	MAE	R^2	说明
B4 跨族收敛点	真实	57	0.293	0.227	0.605	12 个模型族
B5 文献基准	真实	44	0.198	0.171	0.731	已发表数据
B3 插值轨迹	插值	4000	0.004	0.003	1.0000	由 B1 插值生成，非独立
B2 半合成族外	半合成	1029	1.243	1.178	-5.07	坐标平移 1.18 nat，不可比
B10 大模型估算	估算	128	0.001	0.001	1.0000	由拟合参数反推，非独立

唯一具有独立泛化意义的是 **B4 与 B5**：它们来自 12 个模型族与已发表文献，含真实散布， R^2 分别为 0.605 与 0.731，RMSE 为 0.20~0.29 nat。B3 由 B1 插值而来、B10 由拟合参数反推， R^2 接近 1 是同义反复，不构成验证。

B2 的 $R^2 = -5.07$ 源于其损失坐标整体平移约 1.18 nat（不同 tokenizer 与验证集），直接套用 B1 参数必然失配。本文如实报告这一负结果，并说明该数据只能用于族内排序验证。

适用范围：本文的广义标度律在 $N \in [0.07, 12]B$ 、 $D \in [10, 600]B$ 、 $Q \in [0.1, 1.0]$ 内经过检验；超出该范围的预测（包括问题三中大部分最优点、以及问题四的大模型外推）均属外推，在结果中显式标注。

7 问题三：算力约束下的多维资源联合优化与结构性转移

7.1 优化模型

以问题二选定的广义标度律为目标函数，在总算力预算下最小化验证损失：

$$\min_{N,D,Q,p} \hat{L}(N, D, Q, p) = E + AN^{-\alpha} + B [DQ^\kappa h(p)]^{-\beta} \quad (7.18)$$

$$\text{s.t.} \quad \underbrace{6ND}_{C_{\text{train}}} + \underbrace{\eta ND\ell}_{C_{\text{attn}}} + \underbrace{D[g(Q) - g(Q_0)]_+}_{C_Q} \leq C, \quad p_i \geq 0, \sum_i p_i = 1. \quad (7.19)$$

按题面， ℓ 为外生情景变量， p 固定为问题一得到的优选配比（理由见 7.3.2 节）， Q_0 取 0.5。三类质量成本函数为

表 7.15 题给三类质量成本函数

类型	形式	参数	$Q = 1$ 时的单位成本
指数型	$g(Q) = \gamma e^{\lambda Q}$	$\gamma = 10^7, \lambda = 6.0$	4.03×10^9
幂函数型	$g(Q) = \gamma Q^\lambda$	$\gamma = 5 \times 10^9, \lambda = 4.0$	5.00×10^9
对数渐进型	$g(Q) = \gamma \ln(1 + \lambda Q)$	$\gamma = 2 \times 10^9, \lambda = 10.0$	4.80×10^9

三者在 $Q = 1$ 处的量级相近（ $4 \sim 5 \times 10^9$ ），因而比较的是**曲线形状**而非绝对成本水平，这正是题面希望考察的。

7.2 约束化简与解析参照

7.2.1 消去 D

三个成本项共用同一个 D ，约束可整理为

$$D \{ (6 + \eta\ell)N + [g(Q) - g(Q_0)]_+ \} \leq C. \quad (7.20)$$

由于 $\partial L / \partial D < 0$ 恒成立，且题面未给出数据量上限，最优点处约束必取等号，于是

$$D^*(N, Q) = \frac{C}{(6 + \eta\ell)N + [g(Q) - g(Q_0)]_+}. \quad (7.21)$$

代入目标函数后，问题降为 $(\log N, Q)$ 上的二维无约束优化， D 由式 (7.21) 精确回代。这一化简的两个前提（损失对 D 单调、无额外 D 上限）在 7.5 节逐点核验。

7.2.2 固定 Q 时的解析参照

当 Q 固定且无质量开销时， $\partial L / \partial N = 0$ 给出闭式解

$$N^* = \left[\frac{\alpha A (Q^\kappa C / a)^\beta}{\beta B} \right]^{\frac{1}{\alpha + \beta}}, \quad a = 6 + \eta\ell, \quad (7.22)$$

回代得 $D^* = C / (aN^*)$ 。该式用于校验数值搜索的正确性。

7.3 求解方法

7.3.1 为什么不用常规二维优化

本文发现该损失面对 N 极为平坦：在最优解附近， N 变化近两倍而损失变化不足 10^{-4} nat。这种情形下 Nelder–Mead 等直接二维搜索会过早收敛。实测把二者对比：解析最优为 $N^* = 4.46 \times 10^8$ ，而 Nelder–Mead 返回 7.16×10^8 ，相对偏差 60%，尽管损失差仅 9.5×10^{-6} 。

因此本文采用外层 Q 网格 + 内层对 $\log N$ 有界黄金分割极小化 + 坐标下降细化的策略：内层一维搜索用 `minimize_scalar(method='bounded')`，对单峰平坦函数是稳健的；外层在 $Q \in [Q_0, 1]$ 上先取 200 点网格，再在最优邻域内加密。修正后数值解与解析解在全部 15 个 (C, ℓ) 组合上的相对偏差均小于 1.1×10^{-6} （表 7.16）。

表 7.16 解析参照与数值搜索的一致性（固定 $Q = Q_0$ ，指数型成本）

C (FLOPs)	ℓ	N^* 解析	N^* 数值	相对偏差
10^{19}	2 048	2.1348×10^7	2.1348×10^7	9.5×10^{-7}
10^{19}	8 192	1.9722×10^7	1.9722×10^7	2.0×10^{-7}
10^{19}	131 072	1.0298×10^7	1.0298×10^7	6.3×10^{-10}
10^{22}	8 192	4.4620×10^8	4.4620×10^8	6.7×10^{-7}
10^{24}	8 192	3.5692×10^9	3.5692×10^9	8.4×10^{-7}
10^{24}	131 072	1.8636×10^9	1.8636×10^9	1.0×10^{-6}

7.3.2 固定配比的理由

题面允许 p 作为联立决策变量，也允许由前两问确定。本文选择后者，理由有三：（1）问题一已证明配比效应可以跨参数规模迁移（60M 检验集 Spearman 达 0.706），固定优配比是合理的近似；（2）在广义标度律中，配比通过 $h(p)$ 以可分离因子的形式进入，若不引入与配比相关的成本或供给约束，最优 p 将与预算无关，强行做“配比随预算转移”的结论会是伪发现；（3） ω 本身不可辨识（6.4.2 节），联立优化 p 会把这一不确定性放大到配置结论上。本文在 7.6 节对 ω 做了情景敏感性分析。

7.4 优化结果

7.4.1 三档预算与三类成本

表 7.17 给出 $\ell = 8192$ 时的主结果，图 7.12 与图 7.13 给出连续变化。

表 7.17 最优配置（ $\ell = 8192$ ， $Q_0 = 0.5$ ， $\kappa = 1.052$ ）

C (FLOPs)	成本函数	N^* (B)	D^* (B)	Q^*	质量份额	注意力份额	预测损失
10^{19}	指数型	0.0197	66.4	0.500	0%	21.4%	1.69239
	幂函数型	0.0197	66.4	0.500	0%	21.4%	1.69239
	对数渐进型	0.0197	66.4	0.500	0%	21.4%	1.69239
10^{22}	指数型	0.716	1 497	0.826	18.2%	17.5%	1.69066
	幂函数型	0.738	1 384	0.785	22.0%	16.7%	1.69067
	对数渐进型	0.771	1 408	1.000	17.1%	17.8%	1.69063
10^{24}	指数型	5.49	21 842	1.000	8.4%	19.7%	1.69020
	幂函数型	5.60	21 073	1.000	9.9%	19.3%	1.69020
	对数渐进型	5.14	24 708	1.000	3.0%	20.8%	1.69020

7.4.2 三个发现

发现一：质量投入存在明显的“启动预算”。在 $C = 10^{19}$ 时，三个成本函数给出的最优解都把 Q^* 顶在下界 $Q_0 = 0.5$ ，质量份额为 0——低预算下提升数据质量不划算。在 $C = 10^{22}$ 时，最优解进入内部或触及上界，质量份额达 17%~22%。在 $C = 10^{24}$ 时， Q^* 已达到上界 1，质量份额回落到 3%~10%。这一“不投 $\rightarrow$ 大投 $\rightarrow$ 饱和”的模式与题面“家庭收入三阶段”的类比方向一致，但机制不同：不是需求层次变化，而是质量边际收益递减




图 7.12 最优配置随预算的连续变化




图 7.13 成本份额演化与质量投入的三段式结构

与质量边际成本递增共同作用的结果。

发现二：成本函数形状影响启动点与投入强度。三者的质量投入启动点分别为 $\log_{10} C \approx 20.3$ （指数型）、21.0（幂函数型）、20.5（对数渐进型）。对数渐进型在中等预算下最容易达到 $Q^* = 1$ （因为 $g''(Q) < 0$ ，边际成本递减）；幂函数型投入最猛（ $\lambda = 4$ 使 Q 接近 0 时成本极低），但受 $Q \leq 1$ 约束限制，其最大质量份额 22.0% 最高。

发现三：上下文长度严重挤压可用预算。图 7.13(b) 显示，在 $C = 10^{22}$ 时注意力份额自 $\ell = 2048$ 的 5.0% 单调升至 $\ell = 131072$ 的 67.4%。这不只是“注意力贵”，而是它挤掉的是参数与数据的预算：在同一预算下， ℓ 从 2048 增至 131072 使最优参数量下降 82%（ $8.49 \times 10^8 \rightarrow 1.54 \times 10^8$ ）。题面要求的临界值 $\ell_{\text{crit}} = 6/\eta = 30000$ 恰在 8192 与 32768 之间，此时注意力开销与训练开销相当，与表中数据吻合。

7.4.3 结构性转移的识别

题面要求给出结构性转移的明确数学定义与识别方法。本文预先定义三个可检验的事件：

1. 质量投入的启动： Q^* 从下界 Q_0 进入内部，即存在 $\log_{10} C_0$ 使得 $Q^* = Q_0$ 当 $C < C_0$ 、 $Q^* > Q_0$ 当 $C > C_0$ 。
2. 质量投入的饱和： Q^* 触及上界 1。
3. 成本份额的分段：某一成本份额曲线的斜率出现可复现的跳变。

在 $\log_{10} C \in [19, 25]$ 的 61 点连续网格上追踪最优解，得到表 7.18。

表 7.18 结构性转移的识别结果

成本函数	ℓ	Q^* 离开下界的 $\log_{10} C$	质量份额范围	是否复现
指数型	2 048	20.4	0%~18.3%	是
指数型	8 192	20.3	0%~18.3%	是
指数型	131 072	19.6	0%~18.3%	是
幂函数型	8 192	21.0	0%~24.6%	是
对数渐进型	8 192	20.5	0%~40.1%	是

可以确认存在结构性转移，且它属于上述第 1 类事件：质量投入的“从无到有”。该转移在三个成本函数、五档上下文长度下全部复现，启动点稳定落在 $\log_{10} C \in [19.6, 21.1]$ 。

同时必须报告一个否定性结论：在本题的算力代理下，固定 ℓ 时 $C_{\text{attn}}/C_{\text{train}} = \eta\ell/6$ 为常数，因此两个份额之比不会随预算发生结构转移。实测各份额曲线的对数斜率在整个预算区间内平滑变化，未检出第 3 类事件的稳定跳变。若强行把三个离散预算点上的份额差异解释为“结构转移”，属于过度解读。

7.4.4 边界解的解释

题面指出对数渐进型的 $g''(Q) < 0$ 意味着边际成本递减，并非趋近 $Q = 1$ 时发散的成成本，要求如实解释可能的边界解。本文的结果正是如此：对数渐进型在 $C = 10^{22}$ 时已达 $Q^* = 1$ ，这是真实的最优边界解而非数值问题——因为该成本函数下质量的边际成本持续下降，而收益虽递减但仍为正，故只要预算足够就应该把质量做到最好。相反，指数型的 $g''(Q) > 0$ ，质量越接近完美越贵，因此在 $C = 10^{24}$ 时仍可能出现内点解（本算例中已达上界，但敏感性分析显示当 γ 提高一个量级时会退回内点）。

7.5 约束核验与解的辨识性

7.5.1 约束与一阶条件

对全部 45 个主情景逐点回算三项成本，得

- 成本相对残差最大值 2.2×10^{-16} （机器精度），全部满足 $C_{\text{三项和}} \leq C$ ；
- 一阶条件 $|\partial L / \partial \ln N| \leq 1.1 \times 10^{-10}$ ，即内点解的梯度条件严格满足；
- Q 处的库恩–塔克条件：当 $Q^* = Q_0$ 时 $\partial L / \partial Q > 0$ （提高质量会增大损失，故不应投入）；当 $Q^* = 1$ 时 $\partial L / \partial Q < 0$ ；当 Q^* 在内部时 $|\partial L / \partial Q| < 1.2 \times 10^{-7}$ 。符号方向全部正确。

7.5.2 最优规模的辨识很弱

这是本文必须如实报告的一个局限。在最优解附近定义“辨识带”为损失不超过最优点 10^{-4} nat 的 N 取值范围，结果见表 7.19。

预算越高， N^* 的辨识越弱——这与 β 较小、损失面对数据量不敏感直接相关。因此

表 7.19 最优规模的辨识带 ($\Delta L < 10^{-4}$ 的 N 范围)

C	成本函数	N^*	辨识带下限	辨识带上限	带宽倍数
10^{19}	指数型	1.97×10^7	1.00×10^7	4.87×10^7	4.9
10^{22}	指数型	7.15×10^8	1.64×10^8	3.28×10^9	20.0
10^{24}	指数型	5.49×10^9	6.48×10^8	5.24×10^{10}	80.9

N^* 应当作为一个区间而非精确点来解读。相对而言, Q^* 的边界状态(下界/内部/上界)是稳定且可复现的, 质量投入的“三段式”结论比数值本身更可靠。

7.6 敏感性分析

图 7.14(b) 与表 7.20 给出 $C = 10^{22}$ 、 $\ell = 8192$ 处的敏感性。

表 7.20 参数敏感性 ($C = 10^{22}$, $\ell = 8192$, 指数型成本)

情景	N^* (B)	D^* (B)	Q^*	相对基准变化
基准	0.715	1 497	0.826	—
$\kappa = 0.8$	0.672	1 676	0.772	$N - 6.0\%$
$\kappa = 1.3$	0.766	1 330	0.872	$N + 7.1\%$
$Q_0 = 0.3$	0.739	1 413	0.834	$N + 3.3\%$
$Q_0 = 0.7$	0.623	1 902	0.793	$N - 12.9\%$
$\alpha - 10\%$	2.081	522	0.974	$N + 191\%$
$\alpha + 10\%$	0.260	4 166	0.686	$N - 63.6\%$
$\beta - 10\%$	0.199	5 546	0.648	$N - 72.2\%$
$\beta + 10\%$	2.202	494	0.982	$N + 208\%$




图 7.14 (N, Q) 目标曲面与参数敏感性

结论是: 标度律指数 α 、 β 是主导不确定性, $\pm 10\%$ 的扰动使最优规模变化 $-72\% \sim +208\%$; 质量参数 κ 与基线质量 Q_0 的影响温和 ($-13\% \sim +7\%$)。特别值得注意的是, β 减小会使最优规模大幅缩小——因为数据变得更“便宜”后, 应该把预算更多地投向数据而非参数; 反之当数据变贵 (β 增大) 则应转向堆参数。这一权衡关系与问题二的弹性分析结论一致。

另一个需要说明的点: 所有情景下的 N^* 都落在 $0.2 \sim 2.2B$, 低于本文数据支持的参数范围下限 (B1 最小 $0.07B$ 、B6 最小 $0.07B$, 但拟合主要在 $0.07 \sim 12B$ 上进行), 而 D^*

远超数据支持上限（600B）。因此问题三的最优配置整体处于外推区，其绝对数值应谨慎对待；可靠的是其结构性结论（质量投入的三段式、上下文长度的挤压效应、 α/β 的主导性），这些结论在参数扰动下稳定复现。

8 问题四：技术演进分析与前沿预测

8.1 口径统一

前三问以交叉熵损失为对象，本问转向多维 Benchmark 得分，因此必须先统一四个口径，否则后续分解无从谈起。

能力度量。采用 C1 榜单的综合得分 Average（六项任务 IFEval、BBH、MATH Lvl 5、GPQA、MUSR、MMLU-PRO 的等权平均），缺失任务不自动按剩余项平均冒充完整六维分数。

逐任务聚合。题面要求至少完成一项逐任务聚合。本文对 C8 的 1958 份 JSON 解析 BBH 的 24 个子任务，做宏平均（子任务等权）并以题量加权平均作对照，共成功解析 1859 个模型、4 份损坏。只聚合叶子任务，避免了父子任务重复计数。与 C1 的 BBH 列对比发现二者存在稳定的仿射关系：

$$C1_{\text{BBH}} = -36.78 + 1.3249 \times C8_{\text{宏平均}}, \quad \rho = 0.9979. \quad (8.23)$$

这说明 C1 的 BBH 列并非原始正确率，而是经过归一化（很可能是随机猜测校正）后的分数，直接把 C8 的 acc_norm 乘 100 替代榜单分是错的。这一核对确认了本文使用 C1 Average 作为能力度量的合理性。

时间轴。以 C1 的提交日期为主，C2 的 Epoch AI 发布日期仅作敏感性对照，不混用。样本覆盖 2024-06-08 至 2025-03-13，分析截止日 t_0 取 2025-03-13。

开源筛选。严格口径要求 C4 的 Open model weights? 为 Yes（802 个模型），宽松口径要求榜单 Hub License 非空（2810 个模型）。题面要求预测开源模型的前沿，故主预测使用宽松口径的前沿基准 $S_0 = 37.70$ ；严格口径的前沿为 36.26，两者相差 1.44 分。无法判定开放性者进入未知组，不自动归类。

模型类型。按 C1 的 Type 列区分预训练模型（3858 个）与对话/微调模型（718 个），在回归中作为哑变量。

8.2 C4 元数据匹配

题面要求使用 C4 的算力、数据量、开源权重等字段。C4 采用 Epoch AI 的自有命名（如“Llama 3.1-8B”），与榜单的“org/model”命名差异很大，直接同名匹配覆盖率仅 2.4%。本文设计了分层匹配规则：

- **high:** 规范化短名（去机构前缀、去非字母数字、转小写）完全相同，107 个；
- **medium:** 一方是另一方的前缀（处理 -Chat、-32K、-Instruct 等后缀）且参数量比在 $[0.95, 1.05]$ 内，660 个；
- **low:** 前缀关系且参数量比在 $[0.9, 1.11]$ 内，43 个（仅作审计，不进主分析）。

总覆盖率升至 **17.7%**（810/4576）。同时限制 C4 只取 Language 域、且发布日期不晚于 t_0 ，以避免使用未来信息。近 3800 个未匹配模型在元数据相关分析中显式排除，并在结果表中标注样本量。

8.3 Loss-Benchmark 桥接

前三问的结论建立在交叉熵损失上，要转成能力必须建立桥接。题面要求按可比性等级区分使用。本文对 C6 的 75 个模型按 Loss_Comparability 分层拟合

$$S = a - bL, \quad b \geq 0, \quad (8.24)$$

结果见表 8.21 与图 8.15。

表 8.21 Loss-Benchmark 桥接拟合（按可比性分层）

数据集	可比性等级	点数	a	b	R^2
C6 扩展	High（同模型同验证集）	7	7.672	-0.882	0.158
	Medium（不同验证集，近似）	68	61.434	-19.185	0.252
C5 原始	High	7	7.672	-0.882	0.158
	Medium	36	48.929	-14.529	0.240




图 8.15 桥接拟合与留一验证

桥接质量很差，这是本文必须如实报告的核心局限。高可比组只有 7 个点（全部是 Pythia 系列，且 D 固定在 299.9B）， R^2 仅 0.158；中可比组 68 个点， R^2 也只有 0.252。留一模型验证的 MAE 为 7.34 分、RMSE 为 9.59 分。图 8.15(a) 直观显示，同一损失水平下的榜单得分离散度极大——这是因为不同模型族的 tokenizer、训练数据与对齐方法差异，使“损失 $\rightarrow$ 能力”并非单值映射。

因此本文的立场是：桥接只用于把损失的变化量近似折算成能力的变化趋势，不用于绝对水平预测；所有涉及桥接的结论都在预测区间中计入这一误差。这与题面“讨论映射误差对结论的影响”的要求一致。

8.4 能力模型与贡献分解

8.4.1 模型比较

本文比较了 5 个能力模型，均以综合得分 S 为因变量：

表 8.22 能力模型比较（因变量：C1 综合得分）

模型	样本数	R^2	调整 R^2	RMSE
M1: $\log N + t + \text{type}$	4 561	0.465	0.464	7.90
M2: $\log C + t + \text{type}$	627	0.485	0.482	7.72
M3: $\log N + \log C + t + \text{type}$	627	0.527	0.524	7.39
M4: $\log C + t + \text{type} + \text{open}$	595	0.497	0.493	7.68
M5: $\log C + t + \text{type}$ （高置信匹配）	595	0.490	0.487	7.73

M1 覆盖最广（4561 个模型）且只用榜单自带参数量，作为主模型用于分解：

$$S = 13.70 + 14.334 \log_{10} N + 12.846 t + 1.732 \text{ chat}. \quad (8.25)$$

系数解读：参数量每增加 10 倍约提升 14.3 分；控制参数量与类型后，时间趋势为每年 +12.85 分；对话微调模型平均比同规模预训练模型高 1.73 分。M3 同时放入 $\log N$ 与 $\log C$ 后拟合最好，但二者高度相关（ $C \approx 6ND$ ），系数不可分别解释，故不作主模型。

8.4.2 贡献分解

题面要求分离规模扩张与非规模技术进步的贡献。直接用季度平均能力做分解会被组成变化污染——本文数据确实显示季度平均 $\log_{10} N$ 从 0.944 降到 0.757（因为提交的小模型越来越多）。因此主分解建立在**固定组成子集**（ $\geq 7B$ 的预训练模型，组成相对稳定）上：

$$\Delta S_{\text{scale}} = b_N \Delta \log_{10} N, \quad \Delta S_{\text{non-scale}} = r \Delta t, \quad \Delta S_{\text{resid}} = \Delta S - \Delta S_{\text{scale}} - \Delta S_{\text{non-scale}}. \quad (8.26)$$

由于模型对对数变量是线性的，两种因素更新顺序给出完全相同的贡献（顺序差为 0），无需再做顺序平均；这一点已单独验证并记录。

表 8.23 贡献分解（固定组成子集： $\geq 7B$ 预训练模型）

季度	ΔS	规模贡献	非规模贡献	未解释	规模占比
2024Q2→2024Q3	3.169	-0.291	+3.236	+0.225	-9.2%
2024Q3→2024Q4	5.228	-0.268	+3.236	+2.260	-5.1%
2024Q4→2025Q1	1.133	-0.356	+3.165	-1.676	-31.4%
合计	9.530	-0.916	+9.636	+0.810	-9.6%




图 8.16 能力演进时序与贡献分解

核心结论：在这段窗口内，能力提升 9.53 分中规模项为 -0.92 分（-9.6%），非规模技术进步为 +9.64 分（101.1%），未解释部分仅 8.5%。也就是说，能力增长几乎全部来自数据工程、对齐方法与架构改进等非规模因素，而前沿模型的参数量在这一时期并未增大——固定组成子集的平均 $\log_{10} N$ 在三段区间内均为负贡献。这与题面引用的“8B 小模型胜过 GPT-4o”的现象在方向上一致。

需要如实说明三点边界：（1）该分解的是模型预测变化而非全部观测变化，未解释的 8.5% 包含组成变化与遗漏因素；（2）时间项 r 只表示“控制规模与类型后的剩余趋势”，不构成因果识别，它还可能包含评测口径变化、数据污染、后训练算力增加等遗漏因素；（3）分位数前沿口径的分解未解释比例高达 62%，因为前沿模型的参数量波动更大，故以固定组成口径为主报告。

8.5 前沿预测

8.5.1 算力增长率

预测需要未来算力路径。C1nC4 匹配子集的时间跨度仅 0.76 年，不足以估计趋势，故本文改用 C4 全量 Language 域历史（2019-01 至 2025-03，558 个模型）的前沿训练算力做 0.9 分位回归，得

$$g = 0.628 \text{ dex/年} \quad (\text{即前沿算力约每年} \times 4.2).$$
 (8.27)

需要说明，逐年最大值口径给出 0.480 dex/年，与分位回归的 0.628 存在差异，反映估计的不稳定性；本文取二者的中位数并在情景中覆盖这一不确定性，而不是声称已精确测得增长率。

8.5.2 最优路径上的能力增长

在算力最优配置下，由问题三的解析解可得 $N^* \propto C^{\beta/(\alpha+\beta)}$ 、 $D^* \propto C^{\alpha/(\alpha+\beta)}$ ，代入 $\alpha = 0.340$ 、 $\beta = 0.280$ 得份额 $w_N = 0.452$ 、 $w_D = 0.548$ 。于是未来能力的预测式为

$$S(t) = S_0 + (b_N w_N + r/g) \cdot g(t - t_0) + r(t - t_0),$$
 (8.28)

即规模路径贡献 $b_N w_N g \Delta t$ 、非规模趋势贡献 $r \Delta t$ 。三档情景取 g 、 $0.5g$ 、 $0.1g$ ，分别对应“增长延续”“增长放缓”与“算力近乎不变”。参数不确定性用对模型重采样 400 次的 bootstrap 传播。

表 8.24 开源模型能力前沿预测（ $t_0=2025-03-13$ ， $S_0=37.70$ ）

算力情景	月份	规模贡献	非规模贡献	前沿预测	95% bootstrap 区间
增长延续 (g)	12	+4.06	+12.85	54.61	[52.80, 55.64]
	24	+8.13	+25.69	71.52	[68.61, 73.69]
增长放缓 ($0.5g$)	12	+2.03	+12.85	52.57	[50.81, 53.56]
	24	+4.06	+25.69	67.45	[64.65, 69.57]
算力近乎不变 ($0.1g$)	12	+0.41	+12.85	50.95	[49.25, 51.91]
	24	+0.81	+25.69	64.20	[61.42, 66.21]




图 8.17 前沿预测与算力情景对比

结果解读。12 个月后开源模型能力前沿预计达 50.9~54.6 分，24 个月后达 64.2~71.5 分。一个值得注意的结论是：三档算力情景的差异远小于时间趋势本身的贡献——即便算

力增长降到十分之一，24 个月后的预测仍有 64.2 分，而增长延续也只到 71.5 分。这直接来自 8.23 节的分解结论：能力增长主要不靠算力堆叠。这一结论与问题三“质量投入存在启动预算、非规模因素更关键”的发现相互印证。

8.5.3 饱和警示与外推边界

必须显著标注一个边界：样本内综合得分的最大值为 **52.08** 分（99.9 分位 48.04），而 24 个月的预测值 64.2~71.5 分**全部越过该上限**。这说明线性时间趋势外推在长跨度上不可持续——榜单存在实际可达上限，且趋势项 r 不可能永远保持每年 12.85 分。

因此表 8.24 应读作“**按现有趋势的上界估计**”，不是可信的点预测。12 个月的预测（50.9~54.6）仅略微越过上限，可信度相对较高；24 个月的预测则明显属于外推，其价值在于给出量级与情景对比，而非精确数值。

另一方面，未来最高分还取决于参评模型的数量——提交的模型越多，出现的最高分越高。本文不建模这一数量效应，因此采用**高分位数前沿**（0.9 分位）而非“未来一定出现的最高分”，符合题面的表述要求。

8.5.4 回测

用时间滚动切分做回测：在每个历史截止点重新拟合，用其后 90 天的数据评估。

表 8.25 时间滚动回测（训练用过去，评估用未来 90 天）

截止点	训练样本	测试样本	RMSE	MAE	预测均值/真实均值
2024-10-01	1 282	1 316	8.20	6.51	22.28 / 22.52
2024-11-01	1 714	1 765	7.81	6.09	22.31 / 22.46
2024-12-01	2 088	2 131	8.29	6.41	23.99 / 23.13
2025-01-01	2 659	1 902	9.09	6.94	25.76 / 22.78

四个截止点的 RMSE 在 7.8~9.1 分之间，均值预测与真实均值接近（偏差在 -2.98 ~ +0.86 分）。最后一个截止点的预测偏高 2.98 分，提示当模型组成快速变化时（该窗口内大量小模型涌入）预测会失准。回测样本量有限（仅 4 个截止点），该结果反映的是量级而非精确的预测精度。

9 误差分析、模型检验与灵敏度

各问的结果已在相应章节给出局部敏感性。本节做三项横向汇总：数值正确性的核验、误差来源的分解、以及结论对关键假设的稳健性。

9.1 数值正确性核验

表 9.26 汇总了本文为各问设置的正确性检验。所有检验均以独立于求解路径的方式实施（解析解、有限差分、资源守恒），而非重复同一次计算。

其中问题三的解析参照检验值得单独说明：本文最初使用常规二维 Nelder-Mead 搜索时，数值解与解析解相差 60%，但损失差仅 9.5×10^{-6} ，极易被误判为“已经收敛”。正是解析参照暴露了这一问题，促使本文改用“外层网格 + 内层一维精确极小化”的策略，修正后偏差降至 10^{-6} 量级。这说明在平坦损失面上，只看损失值不足以判断解的正确性，必须与解析参照对照。

9.2 误差来源分解

本文的误差可归为四类，表 9.27 给出各自的量级与影响范围。

表 9.26 数值正确性核验汇总

问题	检验方式	检验内容	结果
一	一对一连接核对	A4/A5 等六对表的 index 与列序	全部一致
一	归一化核对	配比行和偏离 1 的最大值	$< 0.4\%$, 已行归一化
一	bootstrap 稳定性	1768 个交互系数的 $ b /sd$	27.3% 显著
二	有限差分	解析弹性 vs 中心差分	偏差 $< 1.8 \times 10^{-12}$
二	解析参照	分组留出 vs 全样本拟合	参数一致
三	解析参照	式 (7.22) vs 数值搜索 (15 组)	相对偏差 $< 1.1 \times 10^{-6}$
三	资源守恒	三项成本之和 vs 预算 C (45 组)	相对残差 $\leq 2.2 \times 10^{-16}$
三	一阶条件	$ \partial L / \partial \ln N $ 与 Q 的 KKT 符号	全部满足
四	聚合口径	BBH 宏平均 vs 题量加权 vs 榜单值	仿射关系 $\rho = 0.9979$
四	分解加和	规模 + 非规模 + 残差 = ΔS	恒等成立
四	无时间泄漏	回测仅用截止点之前的数据	已核验

表 9.27 误差来源与影响

误差来源	受影响结论	实测量级	处理方式
数据来源虚标 (B1 为生成数据)	标度律参数的泛化性	相对残差 5.9×10^{-5}	改用 B4/B5 作泛化检验
跨源坐标不可比 (B2)	族外验证	平移 1.18 nat	只做排序验证
质量域映射代理 (11 个域)	$Q(p)$ 的绝对值	未直接测得	只用于单调折算, 不做因果解读
桥接误差 (Loss→Score)	问题四绝对水平	留一 MAE 7.34 分	计入预测区间; 只作趋势解读
损失面平坦	问题三的 N^*	辨识带 2.3~91 倍	报告区间而非点估计
组成变化	问题四贡献分解	前沿口径残差 62%	主用固定组成口径

9.3 关键假设的稳健性

假设 3 (有效数据量形式): 改用双通道模型 $A(NQ^\rho)^{-\alpha}$ 后, ρ 与 κ 不可辨识, 置信区间互相覆盖。这说明现有数据无法区分“质量作用于数据效率”与“质量作用于参数效率”, 但两种形式在 $Q \in [0.5, 1]$ 内的预测差异小于 10^{-3} nat, 对问题三的配置结论无实质影响。

假设 4 (预算紧约束): 已在 45 个情景上逐点核验, 成本残差为机器精度, 未发现约束松弛的情形。

假设 6 (跨源同尺度): B6 在 $Q = 1$ 的 45 个点相对 B1 经典律的残差均值为 +0.0036、标准差 0.055。若把基准 Q 从 1 改为 0.95 (即假设 B6 的“完美质量”并非真正完美), κ 的估计仅变化约 3%, 结论稳健。

假设 8 (开源口径): 严格与宽松口径的前沿基准相差 1.44 分 (36.26 对 37.70), 远小于 12 个月的预测增量 (约 12.9 分), 故口径选择不改变主要结论。

质量成本函数: 三类函数的启动点落在 $\log_{10} C \in [19.6, 21.1]$, 跨度 1.5 个数量级。这意味着“质量投入存在启动预算”是稳健结论, 但启动点的具体位置依赖于成本函数的选择, 不应给出单一数值。

9.4 与基线模型的对照

为说明本文模型相对简单做法的增益, 表 9.28 给出与“最低参照”的对照。

最后一行值得展开: 若直接用季度均值做分解, 会得到规模贡献 -122%、非规模贡献 +1974% 这类超出合理范围的数值。这不是模型的错误, 而是组成变化的污染——提交的模型越来越小, 使“平均参数量”下降。改用固定组成子集后, 未解释部分从 62% 降到 8.5%。这说明在做贡献分解前必须先控制组成变化, 否则会得出“规模扩张拖累了能力”的错误结论。

表 9.28 与基线做法的对照

问题	基线做法	本文结果	增益
一（配比）	训练集均值预测	CV RMSE 0.257	基线 RMSE 0.345，改善 25.5%
一（配比）	线性混料	CV RMSE 0.257	线性为 0.283，改善 9.2%
一（质量）	等权算术平均	秩相关 0.665	分组几何平均携带额外信息
二（质量）	不含 Q 的经典律	RMSE 0.117	常数基准 0.345，改善 66.1%
二（质量）	$\kappa = 1$ 的约束模型	秩相关 > 0.999	与自由估计几乎等价
四（能力）	仅用参数量	R^2 0.465	加入时间与类型效应
四（分解）	季度均值分解	固定组成分解	避免组成变化造成的 -122% 伪贡献

10 模型评价与推广

10.1 模型优点

一、口径统一、来源可核验。全文对 46 份数据文件逐份审计并给出哈希，把数据分为真实、半合成、插值、估算四级，每一处结论都注明其证据属于哪一级。特别是本文通过残差结构分析识别出标注为“真实训练日志”的 B1 实为公式生成数据，并据此调整了泛化检验的策略——若不区分，会把“还原生成参数”误当成“发现真实规律”。

二、结论与证据强度匹配。对可以精确求解的部分（问题三的最优配置、问题二的弹性）给出解析参照与机器精度级的核验；对不可辨识的部分（配比的 ω 、桥接斜率、最优规模的平坦带）明确报告不可辨识，用区间或情景代替点估计，不用数值优化器的返回值掩盖证据不足。

三、把“数据本身是否可信”纳入建模流程。本文没有把来源分级当作事后的说明文字，而是让诊断结果实际改变建模路径：B1 的合成性使本文改用 B4/B5 做泛化检验；B2 的坐标平移使其退出绝对比较；B8 的外推点使其退出 κ 的分阶段估计。这些“负面结果”都保留在论文中。

四、结构性结论对参数扰动稳健。问题三的“质量投入三段式”在三个成本函数、五档上下文长度下全部复现；问题二的 $\kappa \approx 1$ 在 B6、B7 两个独立数据集上分别得 1.052 与 1.076。这些是本文最可信的结论。

10.2 模型缺点与局限

一、质量数据的来源替换。A1–A3 的原始文件在仓库中为 Git LFS 指针且实体未上传，本文按《数据说明》给出的公开来源同源重建。重建的 A2 为 17438 条（原记载 17523 条，差 0.5%），A1 为 50412 条（目标 51230 条，book 域受下载预算限制少 788 条）。虽然字段结构与域级统计高度一致，但抽样方式与原发布版不可能完全相同，相关的绝对数值应以本文重建口径为准。

二、质量域映射存在代理。17 个配方域中有 11 个没有对应的质量信号域，其质量值由文本体裁代理给定。这使得 $Q(p)$ 的绝对值带有未量化的系统偏差。本文的对策是只把 $Q(p)$ 用于单调折算，不做域级因果解读。

三、配比因子不可辨识。 $h(p)$ 中的迁移强度 ω 缺少与附件 A 的共同实验，只能作为情景变量。这使问题三中最优配比 p^* 无法内点求解，本文固定 p 处理并在敏感性中覆盖 ω 的取值。

四、桥接误差大。Loss 与 Benchmark 之间的映射 R^2 仅 0.16~0.25，留一 MAE 达 7.34 分。这直接限制了问题四预测的精度，也是 24 个月预测越过样本内上限却无法给出可信区间的根本原因。

五、算力增长率估计不稳。C1nC4 匹配子集时间跨度仅 0.76 年，本文改用 C4 全量历史估计，得 0.628 dex/年；但逐年最大值口径给出 0.480，两者差异反映估计的不稳定。本

文以情景覆盖而非声称精确测得。

六、外推占比高。问题三的全部最优配置都超出数据支持的 N 、 D 范围，问题四的 24 个月预测超出样本内得分上限。这些结果的**结构性结论**（方向、次序、边界状态）比数值本身更可信。

10.3 改进方向

一、补充质量信号的实测覆盖。若能获得 17 个配方域的实测质量评分， $Q(p)$ 的代理偏差即可消除，问题三中的配比内点优化也随之可行。

二、设计配比与质量的联合实验。当前 ω 不可辨识的根源是附件 A 与 B 的实验相互独立。若能在同一实验中同时变动配比与质量，即可辨识 $h(p)$ 的迁移强度，把问题三的固定配比假设升级为联立优化。

三、用更丰富的桥接数据降低映射误差。现有桥接的高可比样本仅 7 个且全部来自同一模型族。若能补充多族、多验证集的配对观测，桥接的 R^2 有望显著提升，问题四的预测区间也随之收窄。

四、建模参评模型数量效应。未来最高分取决于参评模型数，本文用 0.9 分位前沿回避了这个问题。若建立“提交数量 $\rightarrow$ 极值分布”的模型，可以给出更贴近“最高分”的预测。

五、引入真实的数据供给约束。本文按题面假设数据量无上限。现实中高质量数据存在供给上限，加入 $D \leq D_{\max}$ 约束后，高预算区间的结构可能再次改变——这正是题面“数据墙”背景所指向的方向。

10.4 推广应用

本文的方法框架不限于语言模型，可推广到三类问题：

一、算力与数据的采购决策。问题三的“质量投入启动预算”给出了一个可直接使用的判据：当预算低于某个阈值时，把钱花在清洗数据上不如扩大模型；超过阈值后质量投入的边际收益才转正。表 7.18 的启动点可直接作为决策参考。

二、多源异构数据的融合评价。“组内平均 + 组间几何平均 + 凸组合消解”这一套评分框架，可直接迁移到任何“多个方向不一的指标需要合成单一得分、且指标间存在冲突”的场景，如教学质量评估、供应商评价、环境质量指数构建。

三、技术进步的贡献分解。问题四“固定组成子集 + 对数线性模型 + 顺序无关分解”的做法，可推广到任何“规模扩张与技术改进共同驱动指标增长”的领域，如光伏组件效率、芯片制程算力、农作物单产。本文特别提示：**分解前必须控制组成变化**，否则会得出符号相反的结论。

10.5 AI 使用披露

按题面要求，本文披露人工智能工具的使用情况：

- **所用工具：**Claude（Anthropic 公司），通过 MathModel 桌面端调用，模型为 Claude 系列。
- **使用环节：**（1）代码调试与语法纠错；（2）绘图脚本的模板改写；（3）文字表达的润色与排版。
- **未使用环节：**模型的数学形式选择、公式推导、参数辨识策略、结构性转移的判据设计、以及全部结论的取舍，均由参赛队完成。
- **核验方式：**所有数值结果均由参赛队独立运行代码复算，解析参照、有限差分与资源守恒三类检验（见表 9.26）用于交叉验证；AI 未参与任何结论性判断。
- **文献：**全部参考文献均通过 Crossref 或 arXiv 官方接口核对元数据后引用，未使用 AI 生成的文献条目。

参考文献

- [1] Bahri Y, Dyer E, Kaplan J, et al. Explaining neural scaling laws[J]. Proceedings of the National Academy of Sciences, 2024, 121(27). DOI: 10.1073/pnas.2311878121.
- [2] Kaplan J, McCandlish S, Henighan T, et al. Scaling Laws for Neural Language Models[J]. arXiv preprint arXiv:2001.08361, 2020.
- [3] Hoffmann J, Borgeaud S, Mensch A, et al. Training Compute-Optimal Large Language Models[J]. arXiv preprint arXiv:2203.15556, 2022.
- [4] Biderman S, Schoelkopf H, Anthony Q, et al. Pythia: A Suite for Analyzing Large Language Models Across Training and Scaling[C]. ICML, 2023. arXiv:2304.01373.
- [5] Liu Q, Zheng X, Muennighoff N, et al. RegMix: Data Mixture as Regression for Language Model Pre-training[C]. ICML, 2024. arXiv:2407.01492.
- [6] Zhuang X, Peng J, Ma R, et al. Meta-rater: A Multi-dimensional Data Selection Method for Pre-training Language Models[J]. arXiv preprint arXiv:2504.14194, 2025.
- [7] Muennighoff N, Rush A M, Barak B, et al. Scaling Data-Constrained Language Models[C]. NeurIPS 36, 2023. arXiv:2305.16264.
- [8] Penedo G, Kydlíček H, Ben allal L, et al. The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale[C]. NeurIPS 37, 2024. arXiv:2406.17557.
- [9] Li J, Fang A, Smyrnis G, et al. DataComp-LM: In Search of the Next Generation of Training Sets for Language Models[C]. NeurIPS 37, 2024. arXiv:2406.11794.
- [10] Albalak A, Elazar Y, Xie S M, et al. A Survey on Data Selection for Language Models[J]. arXiv preprint arXiv:2402.16827, 2024.
- [11] Sorscher B, Geirhos R, Shekhar S, et al. Beyond Neural Scaling Laws: Beating Power Law Scaling via Data Pruning[C]. NeurIPS 35, 2022. arXiv:2206.14486.
- [12] Lee K, Ippolito D, Nystrom A, et al. Deduplicating Training Data Makes Language Models Better[C]. ACL, 2022: 8424–8445. DOI: 10.18653/v1/2022.acl-long.577.
- [13] Hu S, Tu Y, Han X, et al. MiniCPM: Unveiling the Potential of Small Language Models with Scalable Training Strategies[C]. ACL, 2024. arXiv:2404.06395.
- [14] Schaeffer R, Miranda B, Koyejo S. Are Emergent Abilities of Large Language Models a Mirage?[C]. NeurIPS 36, 2023. arXiv:2304.15004.
- [15] Asai A, He J, Shao R, et al. Synthesizing scientific literature with retrieval-augmented language models[J]. Nature, 2026, 650(8103): 857–863. DOI: 10.1038/s41586-025-10072-4.
- [16] Hugging Face. Open LLM Leaderboard v2[EB/OL]. https://huggingface.co/spaces/open-llm-leaderboard/open_llm_leaderboard, 2024. 访问日期 2026-09-23.
- [17] Epoch AI. Data on All AI Models[EB/OL]. https://epoch.ai/data/all_ai_models.csv, 2026. 访问日期 2026-09-23.

附录 A 程序说明与核心代码

A.1 运行环境与复现方式

全部计算在普通个人电脑上完成，无须 GPU。环境与依赖：

- Python 3.12.14（uv 管理的虚拟环境 `venv`）
- numpy 2.x、pandas 2.x、scipy 1.x、scikit-learn 1.x、statsmodels、pyarrow
- matplotlib、seaborn（绘图，中文字体 SimSun，输出 DPI ≥ 330 ）
- 编译：XeLaTeX（MiKTeX 25.12）

代码按问题独立分文件,可单独运行,中间结果以 CSV/JSON/Parquet 落盘于 results/:

表 1.29 代码文件与产出对应关系

文件	对应问题	主要产出
code/common.py	公共	路径、来源分级、全局绘图样式
code/p0_audit.py	P0 数据审计	audit_files.csv
code/fetch_quality.py	数据重建	A1/A2/A3 同源重建
code/q1_quality.py	问题一（质量）	q1_domain_quality.csv 等
code/q1_mixture.py	问题一（配比）	q1_mixture_eval.csv 等
code/q1_integrate.py	问题一（跨体系）	q1_domain_mapping.csv 等
code/q2_scaling.py	问题二	q2_scaling_parameters.json 等
code/q3_optimize.py	问题三	q3_optimal_allocations.csv 等
code/q4_frontier.py	问题四	q4_frontier_forecasts.csv 等
code/figures.py	全部配图	figures/*.png、*.pdf

固定随机种子 20260101；bootstrap 重采样次数在正文各节注明。

A.2 核心代码

以下给出四个关键环节的代码：质量合成与冲突消解、二次混料回归、广义标度律的两阶段估计、以及预算约束下的最优配置搜索。

质量合成与冲突消解（q1_quality.py 节选）

```
# 本程序及代码是在人工智能工具辅助下完成的。
# 工具名称：Claude；开发机构：Anthropic；通过 MathModel 桌面端调用。
# 核心建模逻辑由参赛队设计，AI 仅辅助代码实现与调试。
GROUPS = {
    "教育价值": ["fineweb_edu", "dsir_books", "dsir_wiki", "dsir_math", "qurater", "reason"],
    "可读性": ["read", "clean", "fluency_en", "ue"],
    "专业性": ["prof", "mwl", "fuw"],
    "低噪声": ["ad", "fna", "t2", "t3", "up", "term", "num", "wc", "ns"],
}
NEGATIVE = ["ad", "t2", "t3", "up", "fna", "num"] # 原始越大越差，需补转换
BANDED = ["wc", "ns"] # 适宜区间型，倒 U 型效用
EPS, LAM = 1e-3, 0.3

def fit_norm(df, cols):
    """在开发参考集上冻结归一化参数：1%/99% 分位截尾 min-max。"""
    par = {}
    for c in cols:
        x = df[c].to_numpy(float); x = x[np.isfinite(x)]
        lo, hi = np.percentile(x, 1), np.percentile(x, 99)
        par[c] = (float(lo), float(hi) if hi > lo else float(lo + 1))
    return par

def apply_norm(df, par):
    """方向统一：负向补转换 x->1-x；词数/句数用倒 U 型效用。"""
    out = pd.DataFrame(index=df.index)
    for c, (lo, hi) in par.items():
```

```

        out[c] = np.clip((df[c].to_numpy(float) - lo) / (hi - lo), 0,
            1)
    for c in NEGATIVE:
        if c in out: out[c] = 1.0 - out[c]
    for c in BANDED:
        if c in out:
            out[c] = np.clip(1.0 - np.abs(out[c] - 0.35) / 0.65, 0, 1)
    return out

def composite(z, lam=LAM, eps=EPS):
    """组内算术平均 -> 组间几何平均（短板） -> 凸组合消解冲突。"""
    gs = pd.DataFrame({g: z[[c for c in cols if c in z.columns]].mean(
        axis=1)
        for g, cols in GROUPS.items()}).clip(lower=0)
    q_base = np.clip(np.exp(np.log(gs + eps).mean(axis=1)) - eps, 0, 1)
    gmin = gs.min(axis=1)
    c_i = gs.max(axis=1) - gmin # 冲突强度 c = max_g z
        - min_g z
    Q = (1 - lam) * q_base + lam * gmin # 消解规则
    return Q.to_numpy(float), q_base.to_numpy(float), gs, c_i.to_numpy(
        float)

```

二次混料岭回归（q1_mixture.py 节选）

```

from itertools import combinations
from sklearn.linear_model import Ridge
from sklearn.model_selection import KFold

def design(P, quad=True):
    """Scheffé 规范形设计矩阵：17 个一次项 + 136 个交互项，无截距、无平方项。"""
    cols = [P]
    if quad:
        inter = np.column_stack([P[:, i] * P[:, j]
            for i, j in combinations(range(P.shape
                [1]), 2)])
        cols.append(inter * P.shape[1]) # 尺度对齐，使岭惩罚公
            平
    return np.hstack(cols)

def cv_alpha(X, Y, alphas, k=5):
    """5 折 CV 选择岭惩罚强度：各域标准化 RMSE 均值最小。"""
    kf, scale = KFold(n_splits=k, shuffle=True, random_state=20260101),
        Y.std(axis=0)
    score = np.zeros(len(alphas))
    for tr, va in kf.split(X):
        for ai, a in enumerate(alphas):
            pred = Ridge(alpha=a, fit_intercept=False).fit(X[tr], Y[tr
                ]).predict(X[va])
            score[ai] += np.mean(np.abs(pred - Y[va]) / scale)
    return alphas[int(np.argmin(score))], score / k

def regret(y, yhat, v):
    """Top-k 后悔值：预测最优配方的真实 Loss - 候选集真实最小 Loss。"""

```

```

ty, py = y @ v, yhat @ v
return {f"regret_top{k}": float(np.mean(ty[np.argsort(py)[:k]] - ty
    .min()))
    for k in (1, 5, 10)}

```

广义标度律的两阶段估计 (q2_scaling.py 节选)

```

from scipy.optimize import least_squares

def pred_general(th, N, D, Q, H):
    """ $L = E + A \cdot N^{-\alpha} + B \cdot [D \cdot Q^{\kappa} \cdot h(p)]^{-\beta}$ """
    E, A, al, Bc, be, ka = th
    return E + A * N ** (-al) + Bc * (D * Q ** ka * H) ** (-be)

def fit_general(N, D, Q, H, L, fix=None, n_start=60, seed=20260101):
    """多起点有界 NLS. fix 为自然尺度的固定参数 (非 NaN 位置不估计),
    内部按对数尺度参数化以保证正性, 返回自然尺度参数."""
    r = np.random.default_rng(seed)
    lo = np.log([1e-3, 1e-4, 0.01, 1e-4, 0.01, 0.02])
    hi = np.log([10.0, 1e3, 2.0, 1e3, 2.0, 8.0])
    fix = np.full(6, np.nan) if fix is None else np.asarray(fix, float)
    free = np.isnan(fix)
    lo_f, hi_f = lo[free], hi[free]
    fx_log = np.where(free, 0.0, np.log(np.where(free, 1.0, fix)))
    def res(tf, N, D, Q, H, L):
        t = fx_log.copy(); t[free] = tf
        return pred_general(np.exp(t), N, D, Q, H) - L
    best = None
    for _ in range(n_start):
        s = least_squares(res, r.uniform(lo_f, hi_f), args=(N, D, Q, H, L),
            bounds=(lo_f, hi_f), max_nfev=8000)
        if best is None or s.cost < best.cost: best = s
    th = fix.copy(); th[free] = np.exp(best.x)
    return th, best

# 分阶段估计 kappa: 固定 B1 标定的经典参数, 仅释放 kappa
th_c = fit_classic(N1, D1, L1)[0]
fix_k = np.array([*th_c, np.nan]) # 注意: 自然尺度, 函数
    内部取对数
th_k = fit_general(Nq, Dq, Qq, np.ones_like(Qq), Lq, fix=fix_k,
    n_start=40)[0]
kappa = th_k[5] # -> 1.0524, 95% CI
[0.982, 1.151]

```

预算约束下的最优配置搜索 (q3_optimize.py 节选)

```

from scipy.optimize import minimize_scalar

def D_from_budget(N, Q, C, ell, cf, Q0):
    """消去 D:  $D = C / \{(6 + \eta \cdot \text{ell}) \cdot N + [g(Q) - g(Q0)]_+\}$ """
    return C / ((6 + ETA * ell) * N + max(cf["g"](Q) - cf["g"](Q0),
        0.0))

```

```

def _min_over_N(Q, C, ell, cf, Q0):
    """固定 Q 时对 log N 做有界黄金分割极小化。
    损失面对 N 极平坦 (beta 小)，一维有界搜索比二维 Nelder-Mead 稳健得多。"""
    def f(ln):
        v, _ = L_of_NQ(np.exp(ln), Q, C, ell, cf, Q0)
        return v if np.isfinite(v) else 1e6
    r = minimize_scalar(f, bounds=(np.log(N_MIN), np.log(N_MAX)),
                        method="bounded", options=dict(xatol=1e-12))
    return float(np.exp(r.x)), float(r.fun)

def solve_2d(C, ell, cf, Q0, q_grid=200, band_pts=4000):
    """外层 Q 网格 + 内层一维精确极小化 + 邻域加密。"""
    best = (np.inf, None, None)
    for Q in np.linspace(Q0, 1.0, q_grid):
        N, Lv = _min_over_N(Q, C, ell, cf, Q0)
        if Lv < best[0]: best = (Lv, N, Q)
    span = (1.0 - Q0) / (q_grid - 1) * 8
    for Q in np.linspace(max(Q0, best[2] - span), min(1.0, best[2] + span), 120):
        N, Lv = _min_over_N(Q, C, ell, cf, Q0)
        if Lv < best[0]: best = (Lv, N, Q)
    # 辨识带: Delta L < 1e-4 的 N 区间, 用于提示 N* 的不确定性
    lns = np.linspace(np.log(N_MIN), np.log(N_MAX), band_pts)
    Lv = np.array([L_of_NQ(np.exp(l), best[2], C, ell, cf, Q0)[0] for
                   l in lns])
    ok = Lv <= best[0] + 1e-4
    band = (float(np.exp(lns[ok].min())), float(np.exp(lns[ok].max())))
    return dict(N=best[1], Q=best[2], L=best[0], N_band_1e4=band,
                N_band_ratio=band[1] / band[0])

# 解析参照 (固定 Q=Q0、无质量开销时严格成立)
def analytic_Nstar(C, ell, th):
    a = 6 + ETA * ell
    num = th["alpha"] * th["A"] * (th["Q0"] ** th["kappa"] * C / a) **
        th["beta"]
    return (num / (th["beta"] * th["B"])) ** (1 / (th["alpha"] + th["beta"]))

```

数据来源诊断: 判断损失列是否为公式生成 (q2_scaling.py 节选)

```

def diagnose_sources():
    """对每份标度律数据独立拟合五参数幂律, 据拟合优度与残差结构判定性质。
    判据:  $R^2 > 0.9995$  且相对残差接近舍入量级 -> 判为公式生成。"""
    rows = []
    for tag, fn, level in [("B1 Pythia 训练日志", "
        pythia_training_log_existing.csv", "真实"),
                           ("B4 跨族收敛点", "scaling_baseline.csv", "
        真实"),
                           ("B6 NQ 半合成", "
        supplementary_NQ_experiment.csv", "半合成")]:

```

```

d = pd.read_csv(B / fn).dropna(subset=["N_params_B", "
D_tokens_B", "val_loss"])
n, dd, l = (d["N_params_B"].to_numpy(float), d["D_tokens_B"].
to_numpy(float),
d["val_loss"].to_numpy(float))
th, _ = fit_classic(n, dd, l, n_start=25)
r = 1 - pred_classic(th, n, dd)
r2 = 1 - np.sum(r ** 2) / np.sum((1 - l.mean()) ** 2)
rows.append(dict(dataset=tag, level=level, n=len(l),
rmse=float(np.sqrt(np.mean(r ** 2))), r2=float
(r2),
rel_rmse=float(np.sqrt(np.mean(r ** 2)) / l.
mean()),
verdict=("公式生成（残差≈舍入量级，判为合成）"
if r2 > 0.9995 else "含真实散布")))

return pd.DataFrame(rows)
# B1 结果:  $R^2 = 1.000000$ ,  $rel\_rmse = 5.9e-5$ , 且残差与  $lr/wd/precision$ 
# 的相关系数均  $< 0.09$  -> 判定为公式生成, 其拟合不作为泛化证据。

```